



PERFIL DE PROYECTO DE TESINA PROPUESTO (para postulación a PGE-25)

I. ANTECEDENTES

1.1 Identificación del proponente y candidato a magíster

Nombre del estudiante	EDUARDO MAURICIO AHUMADA GALLARDO
Año de ingreso al Programa	2025
Título del tema propuesto (tentativo)	Clasificación y Extracción de Entidades Nombradas (NER) en Noticias de Cumplimiento Normativo en Empresas Mediante RAG y un Modelo de Lenguaje Grande (LLM) usando ollama
Profesor guía propuesto (tentativo)	JOSE LUIS MARTI LARA
Organización vinculada al proyecto (opcional)	LEANSTACK SPA
¿Su propuesta se basa en una aprobaba anteriormente? (S/N)	S
Si su respuesta es afirmativa, indicar año de aprobación, título del tema y profesor guía asociado.	Clasificación automática de noticias con nombres mediante técnicas CRF (Custom Random Fields) en un proyecto de minería de datos.

II. RESUMEN DE LA PROPUESTA

Defina el contexto y el problema, propuesta de solución, objetivos del trabajo, método(s) de validación y resultados esperados (**máximo 200 palabras**). Finalmente, agregue palabras claves (**máximo 5 palabras**).

RESUMEN:

El contexto del proyecto es la necesidad de instituciones financieras de automatizar el **cumplimiento normativo (KYC, PEP)**. El gran volumen de noticias, obtenidas por suscripción a fuentes públicas (ej. listas de Google), exige una revisión manual ineficiente, elevando costos y riesgos. El problema central es la dificultad para extraer entidades precisas y contextualizadas de cada artículo.

La solución propuesta es un sistema distribuido que emplea la técnica de **Generación Aumentada por Recuperación (RAG)**, tratando **cada noticia individualmente** como fuente de contexto. Esto facilita que un **Modelo de Lenguaje Grande (LLM)** de código abierto (vía **Ollama**) realice el **Reconocimiento de Entidades Nombradas (NER)** (personas, lugares, organizaciones). Las noticias son luego disponibilizadas con las entidades vinculadas, permitiendo a las instituciones financieras compararlas con sus bases de datos para identificar riesgos de cumplimiento.



Los objetivos son: (1) Diseñar la arquitectura RAG/LLM para el análisis de noticias en español; (2) evaluar y comparar el desempeño de **al menos tres LLMs de Ollama (ej. DeepSeek, Gemma)** en la tarea de NER; y (3) Demostrar que el rendimiento de los modelos supera la **línea base de extracción humana**.

La validación se basará en la evaluación cuantitativa del **F1-Score** y la **Precisión** de los LLMs. Los resultados esperados son una extracción de NER de alta calidad y la validación de la utilidad de los LLMs de código abierto en tareas de *compliance* en el mundo real.

PALABRAS CLAVES: NER, COMPLIANCE, CRF, LLM, OLLAMA

III. FORMULACIÓN DEL PERFIL DE LA PROPUESTA

- a) Describa brevemente el contexto organizacional y técnico asociado al trabajo, su experiencia profesional en el tema y defina el problema que se intentará resolver **(40 líneas o ½ página)**

Contexto Organizacional y Definición del Problema

El trabajo de tesina se enmarca en el sector de **Tecnologías de la Información (TI)** para el cumplimiento normativo (**Compliance**), vinculado a la empresa **LeanStack Spa** y la producción de información relacionada con noticias contingentes.

Tener accesibilidad a esta información pública es crucial para bancos e instituciones financieras, ya que les permite cumplir con regulaciones como **KYC (Know Your Customer)** y la administración de **Personas Políticamente Expuestas (PEP)**. La esencia del *compliance* en este contexto es la **identificación y la gestión de riesgos** asociados a clientes y entidades.

Contexto Técnico: El flujo de datos inicia con la suscripción a fuentes de noticias públicas (ej. listas de correo de Google) para obtener un gran volumen de artículos. Estos deben ser procesados por un **sistema distribuido** robusto y escalable. El núcleo técnico del proyecto es la aplicación de **Modelos de Lenguaje Grandes (LLMs) de código abierto (vía Ollama)**, integrados mediante una arquitectura de **Generación Aumentada por Recuperación (RAG)**. La arquitectura RAG es fundamental porque trata **cada noticia individualmente** como la única fuente de contexto, forzando al LLM a fundamentar la extracción de entidades directamente en el texto del artículo.

Experiencia Profesional del Candidato: Mi formación como candidato del **Magíster en Tecnologías de la Información (MTI)** y mi experiencia profesional se centran en la aplicación de **sistemas distribuidos, Machine Learning y análisis de datos**. Este *background* es esencial para el diseño de la arquitectura distribuida (necesaria para manejar el volumen de noticias) y la comprensión de las técnicas avanzadas de **Procesamiento del Lenguaje Natural (PLN)**, lo que me permite seleccionar, implementar y validar de forma rigurosa los LLMs de código abierto para una aplicación de alto impacto regulatorio.

Definición del Problema a Resolver:

El problema principal es la **ineficiencia operativa y el alto riesgo** que implica la revisión manual de noticias para identificar vínculos de *compliance*. El desafío técnico es lograr el **Reconocimiento de Entidades Nombradas (NER)** —identificación de personas, organizaciones, lugares, etc.— con un nivel de **precisión y contextualización** que lo haga útil para la toma de decisiones financieras. Los métodos tradicionales han demostrado ser insuficientes o requerir una inversión prohibitiva en etiquetado. Por lo tanto, el problema se define como la necesidad de **superar la precisión y exhaustividad de la extracción humana** mediante el uso de LLMs asistidos por RAG, garantizando que las entidades extraídas sean lo suficientemente confiables para ser comparadas automáticamente con las bases de datos internas de las instituciones financieras.

b) Defina los objetivos del trabajo y la propuesta técnica de solución (40 minutos o 1/2 página)

Objetivos del Trabajo

Los objetivos específicos del proyecto de tesina se centran en el diseño, la implementación y la validación de un sistema de extracción de información basado en tecnologías de lenguaje avanzado para el sector regulado:

1. **Diseñar la Arquitectura RAG/LLM:** Establecer la arquitectura distribuida completa que integre la Generación Aumentada por Recuperación (RAG) con el Modelo de Lenguaje Grande (LLM) para el análisis automatizado de noticias en español dentro del dominio de *compliance*.
2. **Evaluar el Desempeño de LLMs:** Evaluar y comparar rigurosamente el rendimiento de **al menos tres LLMs de código abierto accesibles mediante Ollama** (como DeepSeek y Gemma) en la tarea de **Reconocimiento de Entidades Nombradas (NER)**.
3. **Superar la Línea Base Humana:** Demostrar cuantitativamente que el rendimiento de los modelos seleccionados supera la **línea base de extracción manual/humana** en términos de precisión y exhaustividad (F1-Score), validando la solución para un entorno de alto riesgo.

Propuesta Técnica de Solución

La solución propuesta es un **sistema distribuido** que procesa grandes volúmenes de noticias (obtenidas por suscripción a fuentes públicas) para generar datos estructurados y contextualizados.

1. **Herramientas Centrales:** La implementación se basará en el lenguaje de programación **Python** (el estándar para el desarrollo de LLMs y RAG) para construir el *pipeline* de procesamiento.
2. **Integración de LLM con Ollama:** Se utilizará **Ollama** como plataforma ligera para descargar, gestionar y ejecutar múltiples Modelos de Lenguaje Grande (LLMs) de código abierto, facilitando la comparativa de modelos.
3. **Mecanismo RAG:** La estrategia clave es la **Generación Aumentada por Recuperación (RAG)**. Cada noticia se trata **individualmente** como el único documento de referencia para el LLM. Este enfoque garantiza que el LLM solo extraiga entidades (personas, lugares, organizaciones) que están **explícitamente contextualizadas** dentro de ese artículo, lo cual es vital para la precisión del *compliance*.
4. **Entrega de Resultados:** Las noticias procesadas serán disponibilizadas con sus entidades NER ya vinculadas. Esto permitirá que las instituciones financieras puedan automatizar la comparación de estas entidades con sus bases de datos internas para la identificación de riesgos de cumplimiento (ej. determinar si un cliente está asociado a una noticia de lavado de activos).

IV. PLAN DE TRABAJO

a) Defina al menos una hipótesis de trabajo y método de validación propuesto (30 líneas)

Hipótesis de Trabajo

La tesis central del proyecto afirma la superioridad de los modelos avanzados y contextualizados:

Hipótesis: "La implementación de un sistema de Generación Aumentada por Recuperación (RAG) con un Modelo de Lenguaje Grande (LLM), utilizando cada noticia como fuente de contexto, logrará una precisión y confiabilidad en la Extracción de Entidades Nombradas (NER) que es superior a la obtenida por los métodos de extracción manual humana, haciendo viable la automatización de alto riesgo en tareas de compliance."

Método de Validación Propuesto

La validación se centrará en la prueba empírica y la comparación directa de la calidad de la información extraída.

Establecimiento de la Línea Base: Se definirá el rendimiento base al hacer que analistas expertos realicen la extracción de entidades en un conjunto de prueba. Este resultado humano será el estándar que los modelos deben superar.

Prueba de Modelos LLM: Se evaluará el desempeño de al menos tres LLMs diferentes (accedidos mediante Ollama) bajo la arquitectura RAG, aplicándolos al mismo conjunto de noticias utilizadas por los humanos.

Comparación de Resultados: La validación se enfocará en demostrar que el modelo LLM+RAG de mejor desempeño ofrece una calidad de datos consistentemente mayor y más completa que la extracción manual.

Confirmación de Fiabilidad: Se verificará que la arquitectura RAG reduce drásticamente los errores de invención (alucinaciones) del LLM, asegurando que solo se extraiga información explícitamente contenida en la noticia.

Este enfoque proporcionará la evidencia necesaria para justificar el uso de la tecnología LLM+RAG en el exigente entorno del compliance.

b) Defina trabajo adelantado y principales tareas que pretende desarrollar próximamente, definiendo plazos que no excedan el 30 de septiembre de 2026 **(30 líneas)**

El trabajo de tesina ya cuenta con un avance significativo en la fase de exploración tecnológica. A continuación, se define el trabajo adelantado y las principales tareas a desarrollar, con plazos definidos que no excedan el 30 de septiembre de 2026.

Trabajo Adelantado y Próximas Tareas

Trabajo Adelantado (Exploración Tecnológica y Prototipado)

El proyecto ha superado la etapa inicial de pruebas de concepto, demostrando la viabilidad de la plataforma técnica:

1. **Viabilidad de la Plataforma:** Se ha confirmado la capacidad de ejecución nativa de Modelos de Lenguaje Grande (LLMs) —específicamente **Gemma, DeepSeek y Llama**— a través de **Ollama** en un entorno de alto rendimiento (Apple M4). Esto valida la estrategia de escalabilidad y bajos costos operativos.
2. **Pruebas de Concepto (PoC) de NER:** Se ha desarrollado código **Python standalone** para realizar el Reconocimiento de Entidades Nombradas (NER) en noticias públicas genéricas, estableciendo la base del código que será adaptado al *pipeline* RAG.
3. **Investigación de Despliegue:** Se ha experimentado con **Streamlit** para la visualización potencial de resultados (interfaz) y con procesos **batch** para asegurar que el sistema pueda manejar grandes volúmenes de noticias de manera eficiente, sentando las bases del prototipo distribuido.

Próximas Tareas y Plazos (Hasta Septiembre 2026)

Plazo	Tarea Principal	Foco
Ene 2026 - Mar 2026	Preparación del Contexto y Datos	- Definir y estructurar el <i>corpus</i> de noticias para las pruebas. - Establecer el "Ground Truth" y la Línea Base Humana para la validación. - Diseñar la arquitectura final RAG/LLM para el dominio <i>compliance</i>.
Abr 2026 -	Implementación y Optimización LLM	- Implementar el <i>pipeline</i> completo RAG en Python/Ollama. - Optimizar los <i>prompts</i> y configuraciones de los tres modelos (Gemma,

May 2026		DeepSeek, Llama) para la extracción de entidades de <i>compliance</i> .
Jun 2026 - Jul 2026	Evaluación y Validación Rigurosa	- Ejecutar la evaluación comparativa de los tres modelos LLM+RAG contra el <i>Ground Truth</i> humano. - Validar la hipótesis principal y demostrar la superioridad del mejor modelo en la extracción de entidades.
Ago 2026 - Sep 2026	Integración y Documentación Final	- Integrar el modelo LLM ganador en un prototipo funcional (utilizando la base <i>batch/Streamlit</i>). - Redacción final, conclusiones y entrega de la tesina.

Nota: Este plan asegura la transición de la experimentación genérica a una solución validada y específica para el sector de *compliance*, con el objetivo de entregar la tesina antes del 30 de septiembre de 2026.

Observación: Si considera necesario, agregue algunas referencias bibliográficas para documentar mejor su perfil de proyecto de tesina. Que no excede al orden de tres referencias.

Implementación de RAG y Uso de Datos Privados:

- Bourne, K. (2024). *Unlocking Data with Generative AI and RAG 2024*.
- Relevancia:** Proporciona un marco práctico y contemporáneo para la implementación de arquitecturas RAG, directamente relevante para la integración de fuentes de datos (noticias) en el *pipeline* del LLM.