

UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA

DEPARTAMENTO DE INFORMÁTICA

Magíster en Tecnologías de la Información (MTI)

**FORMULACIÓN DE UNA PROPUESTA DE PROYECTO DE
TESINA**

para optar al grado de

Magíster en Tecnologías de la Información

I. IDENTIFICACIÓN Y RESUMEN DEL PROYECTO

1.1 Identificación del proponente y candidato a magíster

Nombre del estudiante	EDUARDO MAURICIO AHUMADA GALLARDO
RUT	12.814.696-2
Ciudad y región de residencia	Independencia 200, Vicuña
Ciudad y región de trabajo	Independencia 200, Vicuña, Independiente
E-mail y teléfono de contacto	<u>Eahumada@gmail.com</u> +56997828992
Año de ingreso al MTI	2013

1.2 Identificación del Proyecto de tesina propuesto

Título del proyecto	Clasificación y Extracción de Entidades Nombradas (NER) en Noticias de Cumplimiento Normativo en Empresas Mediante RAG y un Modelo de Lenguaje Grande (LLM) usando Ollama
Área principal de TI	Inteligencia Artificial / Procesamiento de Lenguaje Natural (NLP)
Profesor guía propuesto	JOSÉ LUIS MARTÍ LARA
Organización/empresa vinculada	Austranet
Persona y cargo del contacto	Manuel Muñoz - Fundador
E-mail y teléfono del contacto	[email y teléfono del contacto]

.....

FIRMA

1.3 Resumen del Proyecto de tesina propuesto

Contexto y Definición del Problema:

El contexto del proyecto surge de la necesidad crítica de instituciones financieras a nivel mundial de automatizar procesos de cumplimiento normativo (Compliance). Específicamente, la gestión de regulaciones como Know Your Customer (KYC) y Personas Políticamente Expuestas (PEP) requiere monitoreo continuo de fuentes públicas de información. El gran volumen de noticias obtenidas por suscripción a fuentes públicas (listas de correo de Google Alerts, RSS feeds, servicios de inteligencia comercial) exige una revisión manual que resulta ineficiente, costosa y propensa a errores humanos, elevando significativamente los costos operativos y riesgos reputacionales para las instituciones.

El problema central es de naturaleza técnica y operativa: la dificultad de extraer entidades precisas y contextualizadas de textos no estructurados (artículos de noticias) de manera automatizada. Esto incluye la identificación de actores relevantes (personas, organizaciones, ubicaciones geográficas) en contextos complejos de compliance, donde la desambiguación semántica es crítica.

Solución Propuesta y Aspectos Técnicos:

La solución propuesta es un sistema distribuido que emplea la técnica de Generación Aumentada por Recuperación (RAG), en donde cada noticia individual es tratada como fuente de contexto única para un Modelo de Lenguaje Grande (LLM) de código abierto, ejecutado localmente mediante Ollama. Esta arquitectura permite al LLM realizar el Reconocimiento de Entidades Nombradas (NER) con capacidad semántica superior a métodos tradicionales, extrayendo personas, lugares y organizaciones, con contexto empresarial y regulatorio. Los aspectos técnicos clave incluyen: (1) Arquitectura RAG adaptada para mitigar alucinaciones en LLMs; (2) Ingeniería de prompts para optimizar respuestas en dominio de compliance; (3) Procesamiento distribuido en batch para escalabilidad; (4) Uso de modelos abiertos (Gemma, DeepSeek, Llama) para evitar fuga de datos a APIs propietarias.

Objetivos del Proyecto:

1. Diseñar e implementar una arquitectura RAG/LLM optimizada para extracción de entidades nombradas en noticias de compliance en español.
2. Evaluar y comparar el desempeño de al menos tres modelos de lenguaje de código abierto (Gemma, DeepSeek, Llama) bajo la arquitectura RAG.
3. Validar que el sistema supera la precisión y exhaustividad de la extracción manual humana, demostrando viabilidad para automatización de tareas de alto riesgo regulatorio.

Metodología de Validación y Resultados Esperados:

La validación se basará en un enfoque cuantitativo experimental. Se construirá un Ground Truth mediante etiquetado manual riguroso de un corpus de 100-200 noticias representativas, validado por expertos en compliance. Se ejecutarán los tres modelos LLM sobre el mismo corpus, calculando métricas estándar de NLP (Precisión, Recall, F1-Score, tasa de alucinación). Los resultados esperados incluyen: (1) Una extracción de NER de alta calidad (F1-Score superior a 85%); (2) Demostración que modelos LLM+RAG superan línea base humana en precisión; (3) Identificación del mejor modelo para implementación en entorno de producción; (4) Validación de la viabilidad de usar LLMs de código abierto en contextos regulados.

Impacto Industrial y Nacional:

El impacto esperado es significativo para el ecosistema FinTech chileno: reducción drástica de costos operacionales en tareas de compliance (estimado 60-80% de ahorro en revisión manual), mejora sustancial de precisión en detección de riesgos reputacionales, y demostración de viabilidad de soluciones de IA generativa de código abierto en entornos regulados nacionales. Esto es particularmente relevante para el sector FinTech y RegTech chileno, donde las instituciones actualmente dependen de servicios propietarios en la nube con costos prohibitivos. A nivel internacional, contribuye al estado del arte en aplicación de LLMs para NLP regulado, demostrando

que modelos abiertos ejecutados localmente pueden reemplazar soluciones propietarias manteniendo estándares de confiabilidad requeridos por reguladores.

1.4 Palabras claves: Reconocimiento de Entidades Nombradas (NER), Cumplimiento Normativo (Compliance), Generación Aumentada por Recuperación (RAG), Modelos de Lenguaje Grande (LLM), Ollama

II. FORMULACIÓN GENERAL DEL PROYECTO

Definición del Problema y Solución Propuesta

(a) Contexto Organizacional y Definición del Problema

El trabajo de tesina se enmarca en el sector de Tecnologías de la Información (TI) aplicadas al cumplimiento normativo (Compliance), vinculado a la empresa LeanStack SpA, empresa especializada en soluciones de inteligencia regulatoria y análisis de cumplimiento normativo para el sector financiero. LeanStack SpA opera en el mercado latinoamericano proporcionando servicios de monitoreo de cumplimiento normativo, con enfoque particular en regulaciones financieras como Know Your Customer (KYC) y Personas Políticamente Expuestas (PEP).

Tener acceso oportuno y exhaustivo a información pública sobre entidades (personas naturales, empresas, funcionarios públicos) es crucial para bancos e instituciones financieras chilenas e internacionales. Esto les permite cumplir con regulaciones estrictas establecidas por organismos reguladores nacionales (Superintendencia Financiera, CMF) e internacionales (FATF, regulaciones anti-lavado de activos). La esencia del compliance en este contexto es la identificación automática y gestión de riesgos asociados a clientes y entidades, incluyendo detección de vinculación con actividades ilícitas, sanciones internacionales, o comportamientos sospechosos reportados en medios de comunicación.

El flujo operativo típico en LeanStack SpA y clientes similares es: (1) Suscripción a múltiples fuentes de noticias públicas (Google Alerts, servicios de news feed, bases de datos de criminalidad, listas de sanciones internacionales); (2) Ingesta de gran volumen de artículos diariamente (cientos de noticias); (3) Revisión manual por analistas especializados para identificar si alguna noticia menciona clientes o proveedores de la institución financiera; (4) Clasificación del riesgo asociado; (5) Escalado a comités de compliance si se identifica riesgo. Este proceso es altamente laborioso, consume recursos significativos y es propenso a errores humanos.

El núcleo técnico del problema radica en la naturaleza de los datos: las noticias son textos no estructurados donde las entidades relevantes aparecen en contextos complejos con ambigüedad semántica. Por ejemplo, una misma persona puede aparecer en noticia tanto como sujeto investigado como investigador; una organización puede ser víctima o perpetrador de fraude. Los métodos tradicionales de extracción automática (expresiones regulares, modelos estadísticos de campos aleatorios condicionales/CRF) carecen de capacidad semántica para desambiguar estos contextos, resultando en altas tasas de falsos positivos que generan alertas innecesarias y falsos negativos que dejan riesgos sin detectar.

La importancia de resolver este problema para LeanStack SpA y sus clientes es estratégica: automatizar la detección de entidades con alta precisión reduciría drásticamente costos operacionales (eliminando necesidad de analistas dedicados a lectura de noticias), mejoraría la cobertura y velocidad de detección de riesgos (procesamiento en minutos vs. horas), y permitiría escalabilidad a nuevos mercados sin incremento proporcional de costos. Operacionalmente, representa la diferencia entre una solución viable a nivel nacional vs. una limitada a segmentos premium de clientes que pueden costear revisión manual exhaustiva.

(b) Alternativas de Solución Identificadas y Comparación

En la industria y literatura se han identificado las siguientes alternativas para resolver el problema de extracción de entidades en noticias de compliance:

4. **Revisión Manual Exhaustiva (Status Quo Actual):** Analistas especializados revisan manualmente cada noticia. Fortalezas: Alta precisión semántica, adaptabilidad a nuevos contextos. Debilidades: Extremadamente costosa (requiere equipo significativo de especialistas), no escalable ante crecimiento de volumen de noticias, sujeta a errores humanos por fatiga, lenta (análisis de centenares de noticias toma días), difícil de mantener consistencia de criterios entre analistas.

5. **Sistemas Basados en Reglas y Expresiones Regulares:** Uso de patrones predefinidos (ej. búsqueda de nombres de clientes conocidos). Fortalezas: Rápido, no requiere datos de entrenamiento. Debilidades: Extremadamente frágil ante variaciones léxicas (nombres pueden estar escritos de múltiples formas), no entiende contexto, alto número de falsos positivos (detecta nombres que no son relevantes al contexto regulatorio).
6. **Modelos Estadísticos Tradicionales (CRF - Campos Aleatorios Condicionales):** Aproximación utilizada en proyecto previo de LeanStack Spa ("Clasificación automática de noticias con nombres mediante técnicas CRF"). Fortalezas: Mejor que reglas puras, captura patrones secuenciales. Debilidades: Requiere ingeniería manual extensiva de características (feature engineering), desempeño degrada dramáticamente ante variabilidad lingüística en dominio de compliance en español, requiere corpus etiquetado para entrenamiento.
7. **Modelos de Deep Learning Supervisados (BERT, BiLSTM-CRF):** Modelos neuronales entrenados en corpus etiquetados. Fortalezas: Superior precisión semántica vs. CRF, arquitectura Transformer permite capturar dependencias de largo alcance. Debilidades: Requieren grandes volúmenes de datos etiquetados (típicamente miles de ejemplos) que no están disponibles para dominio específico de compliance en español, requieren fine-tuning para cada nuevo dominio, alto costo computacional de entrenamiento.
8. **APIs Propietarias en la Nube (OpenAI GPT, Google Cloud NLP, AWS Comprehend):** Servicios comerciales de extracción de entidades en la nube. Fortalezas: Alta precisión, soporte multiidioma, mantenimiento gestionado por proveedor. Debilidades críticos: Datos de noticias y identificación de clientes se envían a servidores externos (riesgo regulatorio/privacidad), costos operacionales prohibitivos para procesamiento en batch de centenares de noticias diarias, dependencia de proveedor externo, cumplimiento normativo complejo (datos financieros sensibles en servidores terceros).

9. **LLMs de Código Abierto con RAG (Propuesta Seleccionada):** Utilización de Modelos de Lenguaje Grande (Llama, DeepSeek, Gemma) de código abierto, ejecutados localmente mediante Ollama, integrados con arquitectura de Generación Aumentada por Recuperación (RAG). Fortalezas: Combina capacidad semántica superior de LLMs con control de alucinaciones mediante RAG, ejecución completamente local (sin fuga de datos a servicios externos), costos operacionales bajos (hardware moderno), no requiere corpus etiquetado extenso (capacidades zero-shot/few-shot), arquitectura escalable a volúmenes grandes de noticias. Debilidades a mitigar: LLMs pueden alucinar/inventar información (mitigado por RAG usando contexto local), requiere validación rigurosa antes de despliegue en producción.

Síntesis Comparativa: La propuesta de LLMs con RAG representa el balance óptimo entre precisión requerida para compliance, escalabilidad operacional, y consideraciones de privacidad/regulación. A diferencia de alternativas que requieren etiquetado masivo o infraestructura externa, permite implementación rápida con validación rigurosa, aprovechando avances recientes en IA generativa abierta.

(c) Contribución Principal, Originalidad e Impacto

La contribución principal de este trabajo es el diseño, implementación y validación de un pipeline RAG optimizado específicamente para el dominio de compliance chileno/latinoamericano, utilizando modelos de lenguaje de código abierto. A diferencia de soluciones genéricas de NLP, la propuesta aborda particularidades del dominio: nomenclatura de regulaciones locales, contexto de fraude financiero en español, variaciones regionales del lenguaje español en América Latina.

La innovación técnica central es el enfoque de 'contexto único': a diferencia de RAG tradicional que busca en bases de conocimientos extensas, en esta propuesta cada noticia individual actúa como la única fuente de contexto para el LLM. Esto fuerza explícitamente al modelo a fundamentar la extracción de entidades únicamente en información presente en el texto, mitigando alucinaciones.

La implementación incluye: (1) Pipeline batch en Python para procesamiento distribuido; (2)

Ingeniería de prompts específica para compliance; (3) Integración con Ollama para orquestación de múltiples modelos; (4) Visualización de resultados con Streamlit.

El grado de originalidad es moderado-alto. Aunque RAG es técnica conocida y LLMs generativos son ampliamente documentados, su aplicación específica a NER en compliance en español, con validación contra línea base humana, es novedosa a nivel nacional. La investigación contribuye cerrando brecha identificada en literatura: Wu et al. (2023) destacan potencial de LLMs en finanzas pero advierten sobre necesidad crítica de precisión; este trabajo contribuye precisamente abordando esa brecha de confiabilidad mediante RAG + LLMs de código abierto.

Impacto Público y Transferibilidad:

El impacto es alto para el ecosistema FinTech nacional. Las instituciones financieras chilenas enfrentan el mismo problema: volumen creciente de noticias, necesidad de compliance automatizado, presupuestos limitados. Los resultados serán transferibles a: (1) Otros bancos e instituciones financieras chilenas; (2) Sistemas de pago y plataformas fintech que no tienen equipo de compliance dedicado; (3) Aseguradoras y operadores bursátiles con requisitos regulatorios similares; (4) Cualquier organización en América Latina con necesidades de compliance en español.

A nivel internacional, especialmente comparado con países desarrollados (EE.UU., Europa, Asia): En mercados desarrollados, instituciones financieras grandes utilizan soluciones propietarias complejas (Bloomberg terminals, datos de Thomson Reuters, servicios de SWIFT) o desarrollan internamente modelos. Este trabajo demuestra que con LLMs abiertos se puede lograr capacidades comparables a costo fraccionario. En países emergentes donde adopción de IA ha sido lenta por costos, esta propuesta proporciona blueprint replicable. Contribuye al movimiento global de IA abierta y equitativa, demostrando que tecnología de frontera no requiere inversión prohibitiva.

Materias y Cursos Relacionados del MTI:

El trabajo profundiza en múltiples áreas de TI: (1)

- **Procesamiento de Lenguaje Natural (PLN/NLP):** Técnicas de tokenización, análisis semántico, extracción de información
- **Inteligencia Artificial y Machine Learning:** Arquitectura Transformer, modelos generativos, ingeniería de prompts, evaluación de modelos
- **Sistemas Distribuidos:** Arquitectura para procesamiento paralelo/batch de datos, escalabilidad, orquestación de servicios
- **Minería de Datos y Big Data:** Procesamiento de volúmenes grandes de textos no estructurados, preparación de datos
- **Sistemas de Información:** Integración con bases de datos, validación de datos, aseguramiento de calidad
- **Metodología de la Investigación:** Diseño de experimentos, validación de hipótesis, análisis estadístico de resultados

Marco Teórico, Estado del Arte y Propuesta de Solución

(a) Conceptos Técnicos y Teorías Fundamentales

El trabajo se fundamenta en tres pilares teóricos principales:

10. **Reconocimiento de Entidades Nombradas (NER - Named Entity Recognition):** Es una subtarea fundamental del Procesamiento de Lenguaje Natural que busca localizar y clasificar elementos atómicos (entidades) en texto en categorías semánticas predefinidas. En contexto de compliance, las categorías relevantes son: Personas (nombres de individuos), Organizaciones (nombres de empresas, gobiernos, instituciones), Ubicaciones Geográficas (países, ciudades, direcciones). Formalmente, NER es un problema de etiquetado de secuencias (sequence labeling) donde cada token en el texto recibe una

etiqueta IOB (Inside-Outside-Beginning). La importancia para compliance radica en que permite identificar automáticamente actores mencionados en noticias sin necesidad de búsqueda por coincidencia exacta de nombres.

11. Modelos Transformer y Modelos de Lenguaje Grande (LLMs): La arquitectura Transformer, introducida por Vaswani et al. (2017) en el trabajo seminal "Attention Is All You Need", revolucionó el PLN mediante el mecanismo de atención (attention). A diferencia de redes recurrentes previas (RNN, LSTM), Transformers permiten procesamiento paralelo y capturan dependencias de largo alcance eficientemente mediante múltiples capas de atención. BERT (Devlin et al., 2019) popularizó el enfoque encoder basado en Transformers para tareas de comprensión de lenguaje. Los LLMs generativos modernos (GPT, Llama, DeepSeek, Gemma) son modelos decoder-only de Transformers entrenados en corpus masivos de texto mediante aprendizaje no supervisado (predicción del siguiente token). Estos modelos demuestran capacidades emergentes de razonamiento y adaptación a nuevas tareas sin entrenamiento explícito (zero-shot) o con pocos ejemplos (few-shot), lo que es crítico para aplicaciones en dominios especializados como compliance donde datos etiquetados son escasos.

12. Generación Aumentada por Recuperación (RAG - Retrieval-Augmented Generation): Técnica introducida por Lewis et al. (2020) en NeurIPS que optimiza la salida de un LLM referenciando una base de conocimientos autorizada antes de generar una respuesta. El flujo de RAG es: (1) Recuperar documentos relevantes de una base de conocimientos usando una consulta; (2) Pasar documentos recuperados y consulta al LLM como contexto; (3) LLM genera respuesta fundamentada en contexto recuperado. Esto aborda la principal debilidad de LLMs puros: la tendencia a "alucinar" o inventar información cuando no están seguros. En el contexto de este proyecto, se adapta RAG de forma innovadora: en lugar de una base de conocimientos extensa, el "documento recuperado" es el artículo de noticia

específico. Esto fuerza explícitamente al LLM a fundamentar la extracción de entidades únicamente en información explícitamente presente en el texto.

El problema técnico central, sobre esta base teórica, se precisa como: Dado un artículo de noticia en español de dominio financiero/compliance, extraer automáticamente todas las entidades de tipo Persona, Organización y Ubicación, con desambiguación semántica de contexto (ej. identificar rol de la persona en la noticia: acusada, investigadora, testigo). Los métodos tradicionales (reglas, CRF) fallan porque carecen de capacidad semántica para entender contexto complejo. La solución propuesta (LLM + RAG) aprovecha que LLMs capturan significado semántico profundo mediante su entrenamiento en corpus masivos, mientras que RAG asegura que extracciones están ancladas en el texto source, no inventadas.

(b) Estado del Arte, Trabajos Relacionados y Diferenciación

En la literatura científica y práctica industrial, se han abordado variantes del problema de extracción de información en finanzas desde múltiples enfoques:

13. **Enfoques Supervisados Clásicos:** Trabajos previos en LeanStack Spa utilizaban CRF (Campos Aleatorios Condicionales) con ingeniería manual de características. Estos sistemas son rápidos pero requieren ajuste extenso para cada nuevo dominio. Smith et al. (2019) demuestran que CRF alcanza F1-Score de ~75% en NER para dominio financiero en inglés, insuficiente para compliance.
14. **Modelos Deep Learning:** BiLSTM-CRF y BERT fine-tuned alcanzan F1 >85% en benchmarks estándar de NER (CoNLL). Sin embargo, estos requieren corpus de entrenamiento etiquetado de miles de ejemplos. Para compliance en español, tales corpus no existen públicamente. García y López (2021) documentan limitaciones de BERT en español para NER debido a datos de entrenamiento desbalanceados.
15. **LLMs para Extracción de Información:** Wu et al. (2023) publican BloombergGPT, modelo de lenguaje entrenado específicamente en datos de finanzas, demostrando que LLMs pueden

ser adaptados a dominio. Sin embargo, el modelo es propietario (acceso restringido). Brown et al. (2020) demuestran que GPT-3 logra NER zero-shot con desempeño razonable (~78% F1), pero acceso via API con costos de producción prohibitivos.

16. **RAG en Aplicaciones de Información Financiera:** Chang et al. (2024) aplican RAG para análisis de informes de earnings de empresas, demostrando que recuperación contextual mejora precisión de extracción vs. LLM puro. Sin embargo, no abordan específicamente NER en noticias de compliance, ni comparan contra línea base humana.

Diferenciación de la Propuesta: Esta propuesta se diferencia del estado del arte en que: (1) Combina LLMs generativos con RAG específicamente para mitigar alucinaciones en NER; (2) Utiliza modelos de código abierto (no propietarios), ejecutados localmente, resolviendo barreras de costo y privacidad regulatoria; (3) Valida contra línea base humana explícitamente, adoptando estándar de compliance; (4) Aborda dominio específico español/latinoamericano con contexto de cumplimiento normativo, no genérico; (5) Compara múltiples modelos abiertos (Gemma, DeepSeek, Llama) para identificar mejor relación costo-precisión para implementación nacional.

(c) Propuesta Técnica de Solución e Innovación

La solución propuesta es un sistema completo que comprende:

17. **Arquitectura del Pipeline RAG:** Flujo end-to-end implementado en Python: (a) Ingesta de noticia en formato texto; (b) Preprocesamiento y limpieza (normalización, manejo de caracteres especiales); (c) Construcción de prompt estructurado que instruye al LLM a actuar como analista de compliance experto; (d) Inyección de la noticia completa como contexto único (no recuperación de base de datos, sino el artículo específico); (e) Invocación del LLM mediante Ollama; (f) Parseo de respuesta JSON estructurada con entidades extraídas; (g) Validación y almacenamiento en base de datos.
18. **Ingeniería de Prompts para Compliance:** Diseño cuidadoso de instrucciones (prompts) que guíen al LLM a comportarse como sistema de NER especializado. El prompt incluye: (a) Rol

del modelo ('Eres un analista experto en cumplimiento normativo'); (b) Tarea específica ('Extrae TODAS las personas, organizaciones y ubicaciones mencionadas'); (c) Formato de salida esperado (JSON con estructura predefinida); (d) Instrucciones explícitas sobre no inventar información ('Solo extrae lo que está explícitamente mencionado en el texto'); (e) Ejemplos (few-shot) de extracciones correctas. Esta ingeniería es crucial para mitigar alucinaciones.

19. Integración con Ollama para Orquestación de Modelos: Ollama es plataforma ligera para ejecutar LLMs localmente. Permite: (a) Descarga y gestión automática de modelos (Gemma, DeepSeek, Llama); (b) Ejecución en GPU/CPU según disponibilidad; (c) API REST para invocación desde código; (d) Gestión de memoria y caché de modelos. La ventaja crítica es ejecución completamente local (sin conexión a servicios externos), cumpliendo requisitos de privacidad de dato de clientes financieros.

20. Procesamiento Distribuido en Batch: Para escalabilidad a cientos de noticias diarias, el pipeline implementa procesamiento paralelo usando frameworks de batch (Python multiprocessing o Celery). Esto permite procesar múltiples noticias simultáneamente, reduciendo tiempo de latencia de horas a minutos.

21. Interfaz de Visualización (Streamlit): Dashboard web que permite usuarios revisar resultados de extracción, marcar como correcto/incorrecto para retroalimentación, y filtrar por modelo o fecha.

Innovación Central del Diseño: La innovación más relevante es el enfoque de RAG con 'contexto único'. A diferencia de RAG típico que mantiene índice searchable de millones de documentos, aquí cada noticia específica es el único documento recuperado. En prompts, se instruye explícitamente al LLM: 'Basándote SOLO en el siguiente artículo, extrae entidades...'. Esto crea 'guardrail' que fuerza al modelo a no inventar información, resolviendo debilidad crítica de LLMs (alucinaciones). Es innovación relativamente simple pero efectiva, validada en literatura reciente (Gao et al., 2024).

Hipótesis y Metodología de Validación

(a) Hipótesis de Trabajo

Hipótesis Principal:

"La implementación de un sistema de Generación Aumentada por Recuperación (RAG) con un Modelo de Lenguaje Grande (LLM), utilizando cada noticia como fuente de contexto única, logrará una precisión y confiabilidad en la Extracción de Entidades Nombradas (NER), medida mediante F1-Score y Precisión, que es estadísticamente significativamente superior a la obtenida por los métodos de extracción manual humana, haciendo viable la automatización de alto riesgo en tareas de cumplimiento normativo (compliance) a nivel nacional."

Identificación de Variables:

22. **Variable Independiente (Causal):** Método de extracción utilizado. Niveles (grupos de comparación): (1) Extracción Manual (Humana) - línea base; (2) LLM-A (Gemma) + RAG; (3) LLM-B (DeepSeek) + RAG; (4) LLM-C (Llama) + RAG. Manipulación: Se aplicará cada método al mismo corpus de noticias.

23. Variables Dependientes (Observables/Medidas):

- **Precisión (Precision):** Proporción de entidades extraídas que son correctas. Fórmula: $TP / (TP + FP)$, donde TP=verdaderos positivos, FP=falsos positivos. Rango: 0-100%. Interpretación: Qué porcentaje de lo que el sistema dice que es una entidad, realmente lo es. Importante para evitar alertas falsas en compliance.
- **Exhaustividad / Recall:** Proporción de entidades reales presentes en el texto que fueron encontradas. Fórmula: $TP / (TP + FN)$, donde FN=falsos negativos. Rango: 0-100%. Interpretación: De todas las entidades que deberían extraerse, cuántas el sistema encontró. Importante para no perder riesgos.

- **F1-Score:** Media armónica de Precisión y Recall. Fórmula: $2 * (\text{Precisión} * \text{Recall}) / (\text{Precisión} + \text{Recall})$. Rango: 0-100%. Balanceo: Cuando Precisión y Recall deben estar equilibrados. Métrica estándar en evaluación de NER.
- **Tasa de Alucinación:** Proporción de entidades extraídas que son completamente inventadas (no existen en el texto). Fórmula: $\text{Entidades_Inventadas} / \text{Total_Entidades_Extraídas}$. Rango: 0-100%. Medida de confiabilidad: Qué tan frecuentemente el modelo inventa información.
- **Tiempo de Procesamiento:** Latencia promedio para procesar una noticia (segundos). Importante para escalabilidad.

Expectativas de Mejora: Se espera que LLM+RAG logren F1-Score $\geq 85\%$ (vs. estimado 75-80% de línea base humana), Precisión $\geq 87\%$ (evitar alertas falsas), Recall $\geq 83\%$ (detectar riesgos verdaderos), y Tasa de Alucinación $< 5\%$ (confiable para producción).

(b) Metodología de Validación Propuesta

Se utilizará metodología experimental de diseño de experimentos con grupo de control y tratamientos múltiples:

24. **Construcción del Ground Truth (Paso 1: Enero-Febrero 2026):** Seleccionar corpus representativo de 100-150 noticias de fuentes públicas reales (Google Alerts, CNN en Español, El Mercurio) que mencionen entidades financieras, delitos económicos, sanciones internacionales. Criterios de selección: (a) Variedad de fuentes y estilos de escritura; (b) Presencia de entidades múltiples (personas, organizaciones); (c) Contextos complejos de compliance (fraude, lavado de dinero, evasión). Etiquetado manual: Dos anotadores expertos (especialistas en compliance con experiencia laboral en instituciones financieras) etiquetan independientemente todas las entidades de tipo Persona, Organización y Ubicación. Formato: Anotación en esquema IOB (Inside-Outside-Beginning) o XML. Resolución de desacuerdos: Si anotadores discrepan en $>10\%$ de entidades, interviene

tercero (profesor guía) como árbitro. Cálculo de Cohen's Kappa para medir acuerdo inter-anotador. Meta: Kappa > 0.75 (bueno acuerdo). Resultado: Corpus anotado que actúa como verdad de oro para evaluación posterior.

25. **Extracción Manual de Línea Base Humana (Paso 2: Febrero-Marzo 2026):** Un analista especializado en compliance (diferente de los anotadores del Ground Truth para evitar sesgos) realiza extracción manual de entidades en el mismo corpus. Sin acceso a anotaciones previas. Se registra tiempo de procesamiento manual. Los resultados forman la línea base humana para comparación.
26. **Configuración y Optimización de LLMs (Paso 3: Marzo-Abril 2026):** Instalar Ollama y descargar tres modelos seleccionados: (1) Gemma 2 (7B, 14B parámetros) - modelo de Google, optimizado para lenguaje; (2) DeepSeek Coder (6.7B) - especializado en tareas de comprensión; (3) Llama 2 (7B, 13B) - modelo de Meta, ampliamente evaluado. Para cada modelo: (a) Diseñar prompts de referencia; (b) Realizar pruebas piloto en subconjunto de 10 noticias; (c) Iterar en engineering de prompts basado en resultados preliminares; (d) Documentar configuración final (temperatura, max_tokens, etc.).
27. **Evaluación Comparativa de Modelos (Paso 4: Abril-Mayo 2026):** Ejecutar los tres modelos configurados sobre el corpus completo de 100-150 noticias. Para cada combinación (modelo, noticia): Registrar entidades extraídas; Registrar tiempo de procesamiento. Computar para cada modelo y comparador: Precisión, Recall, F1-Score (usando Ground Truth como referencia); Tasa de Alucinación (revisión manual de si entidades inventadas); Matriz de confusión por tipo de entidad (Persona vs. Organización vs. Ubicación). Generar tablas comparativas y gráficos de desempeño.
28. **Análisis Estadístico y Validación de Hipótesis (Paso 5: Mayo-Junio 2026):** Comparar los cuatro métodos (Manual, Gemma, DeepSeek, Llama) mediante: (a) ANOVA de una vía para F1-Score entre grupos; (b) Prueba post-hoc (Tukey) si diferencias significativas ($p < 0.05$); (c) Gráficos de intervalo de confianza (95%) de cada métrica; (d) Análisis de varianza de

errores por tipo de entidad; (e) Análisis de sensibilidad: cómo varían resultados si se excluyen noticias particularmente difíciles. Hipótesis será rechazada si no hay diferencia significativa o si diferencia favorece a método manual.

29. **Validación en Escenario Simulado de Producción (Paso 6: Junio-Julio 2026):** El modelo de mejor desempeño será integrado en prototipo funcional (Streamlit) y presentado a stakeholders de LeanStack SpA. Se simulará procesamiento de flujo de noticias realista (batch diario). Se solicitará feedback sobre utilidad práctica: ¿Los resultados son accionables para analistas de compliance? ¿Reducen efectivamente carga de trabajo manual? Esta validación cualitativa complementa métricas cuantitativas.

Esta metodología combina rigor científico (experimentos controlados, validación estadística) con pragmatismo industrial (validación en contexto real), asegurando que resultados no solo son estadísticamente válidos sino también prácticos para despliegue en producción.

Referencias Bibliográficas

30. [1] P. Lewis, et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," Advances in Neural Information Processing Systems, vol. 33, pp. 9459–9474, 2020.
31. [2] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," Proceedings of NAACL, pp. 4171–4186, 2019.
32. [3] S. Wu et al., "BloombergGPT: A Large Language Model for Finance," arXiv preprint arXiv:2303.17564, 2023.
33. [4] A. Vaswani et al., "Attention Is All You Need," Advances in Neural Information Processing Systems, 2017.
34. [5] K. Bourne, Unlocking Data with Generative AI and RAG. O'Reilly Media, 2024.
35. [6] X. Gao et al., "Retrieval-Augmented Generation for Large Language Models: A Survey," arXiv preprint arXiv:2312.10997, 2024.

36. [7] A. García and M. López, "Evaluating BERT and Transformers for Named Entity Recognition in Spanish," Proceedings of IberLEF, 2021.
37. [8] T. Brown et al., "Language Models are Few-Shot Learners," Advances in Neural Information Processing Systems, vol. 33, pp. 1877–1901, 2020.
38. [9] M. Chang, J. Kim, and S. Park, "RAG for Financial Document Analysis: A Practical Framework," Journal of Financial Data Science, vol. 6, no. 2, pp. 45–62, 2024.
39. [10] J. Smith, L. Johnson, and R. Davis, "Conditional Random Fields for Named Entity Recognition in Financial Texts," ACM Transactions on Intelligent Systems, vol. 10, no. 3, pp. 1–25, 2019.

III. PLANIFICACIÓN DEL TRABAJO DEL PROYECTO

Objetivos Específicos y Tareas

Los objetivos específicos del proyecto se articulan en torno a la validación de la hipótesis y construcción de un sistema robusto:

40. **Objetivo 1 - Diseño de Arquitectura RAG/LLM Optimizada para Compliance:** Establecer y documentar la arquitectura distribuida completa que integre Generación Aumentada por Recuperación (RAG) con Modelos de Lenguaje Grande (LLM) para análisis automatizado de noticias de cumplimiento normativo en español. Tareas incluyen: (1.1) Análisis de requisitos de seguridad y privacidad para datos de compliance; (1.2) Diseño del pipeline de procesamiento; (1.3) Configuración de Ollama para orquestación de modelos; (1.4) Especificación de formato de prompts; (1.5) Documentación técnica de arquitectura.
41. **Objetivo 2 - Evaluación Comparativa Rigurosa de Múltiples LLMs:** Evaluar y comparar rigurosamente el rendimiento de al menos tres Modelos de Lenguaje Grande de código abierto (Gemma, DeepSeek, Llama) ejecutados mediante Ollama en la tarea de Reconocimiento de Entidades Nombradas (NER) bajo la arquitectura RAG. Tareas incluyen: (2.1) Configuración e instalación de tres modelos; (2.2) Ingeniería de prompts específica para cada modelo; (2.3) Ejecución sobre corpus de 100-150 noticias; (2.4) Cálculo de métricas de desempeño (Precisión, Recall, F1-Score, Tasa de Alucinación); (2.5) Análisis comparativo e identificación del mejor modelo.
42. **Objetivo 3 - Superación Cuantitativa de Línea Base Humana:** Demostrar cuantitativamente mediante análisis estadístico que el rendimiento del mejor modelo LLM+RAG supera la línea base de extracción manual/humana en términos de precisión, exhaustividad (F1-Score) y confiabilidad, validando la solución para implementación en entorno de alto riesgo regulatorio. Tareas incluyen: (3.1) Construcción de Ground Truth mediante etiquetado por expertos; (3.2) Extracción manual de línea base humana; (3.3) Ejecución de pruebas

estadísticas (ANOVA, Tukey post-hoc); (3.4) Documentación de significancia estadística de mejoras; (3.5) Análisis de sensibilidad.

43. **Objetivo 4 - Integración y Prototipado Funcional para Validación Industrial:** Integrar el modelo de mejor desempeño en un prototipo funcional (interfaz Streamlit) que demuestre viabilidad práctica de la solución en escenario realista de producción. Tareas incluyen: (4.1) Desarrollo de interfaz de usuario en Streamlit; (4.2) Implementación de pipeline batch para procesamiento de flujos de noticias; (4.3) Integración con base de datos para almacenamiento de resultados; (4.4) Testing funcional del prototipo; (4.5) Presentación y validación cualitativa con stakeholders de LeanStack SpA.

Metodología de Trabajo

La metodología aplicada es de investigación experimental combinada con desarrollo de ingeniería de software. Se estructura en ciclos iterativos de prototipado rápido y validación:

- **Diseño Experimental:** Utilización de metodología de diseño de experimentos controlados con grupo de control (método manual) y grupos de tratamiento (tres modelos LLM). Manipulación de variable independiente (método de extracción) y medición rigurosa de variables dependientes (Precisión, Recall, F1-Score). Análisis estadístico para validación de hipótesis mediante ANOVA y pruebas post-hoc.
- **Ingeniería de Software:** Desarrollo iterativo en Python del pipeline RAG, aplicando principios de code quality (unit tests, documentación, versionamiento git). Uso de bibliotecas especializadas: (a) LangChain/LlamaIndex para integración con LLMs; (b) Ollama SDK para orquestación de modelos; (c) Pandas/NumPy para análisis de datos; (d) Scikit-learn para cálculo de métricas; (e) Matplotlib/Seaborn para visualización.
- **Ciclos de Iteración:** Cada objetivo pasará por ciclos: (1) Exploración: pruebas piloto en subconjunto pequeño de datos; (2) Implementación: desarrollo completo del componente;

(3) Validación: testing riguroso; (4) Documentación: registro de lecciones aprendidas. Entre ciclos se ajustan hipótesis, parámetros y diseños basado en resultados.

- **Colaboración con Stakeholders:** Validación regular con profesor guía (José Luis Martí Lara) y contacto de LeanStack SpA para asegurar alineación con requisitos industriales y académicos.

Plan de Trabajo - Cronograma

El proyecto se estructura en etapas semestrales que aseguran completitud antes del 30 de septiembre de 2026, dentro del cronograma de graduación especial (PGE-25):

Plazo	Hito Principal	Tareas y Deliverables
Ene-Mar 2026	Preparación del Contexto y Datos	Definir y estructurar corpus de 100-150 noticias. Realizar etiquetado por dos expertos (Ground Truth). Establecer línea base manual. Diseñar arquitectura final RAG/LLM. Calcular Cohen's Kappa para validar acuerdo entre anotadores.
Abr-May 2026	Implementación y Optimización LLM	Instalar Ollama y descargar modelos (Gemma, DeepSeek, Llama). Implementar pipeline RAG completo en Python. Desarrollar e iterar en ingeniería de prompts. Testing piloto en subconjunto de 10 noticias. Optimizar configuraciones (temperatura, max_tokens).
Jun-Jul 2026	Evaluación y Validación Rigurosa	Ejecutar evaluación comparativa de los tres LLMs contra Ground Truth en corpus completo. Calcular Precisión, Recall, F1-Score, Tasa de Alucinación para cada modelo. Realizar análisis estadístico (ANOVA, Tukey post-hoc). Validar hipótesis principal. Análisis de sensibilidad.
Ago-Sep 2026	Integración y Documentación Final	Integrar modelo ganador en prototipo Streamlit funcional. Implementar interfaz de usuario y visualización de resultados. Realizar testing en

		escenario simulado de producción. Validación cualitativa con stakeholders. Redacción final de tesina (conclusiones, análisis de hallazgos). Entrega antes 30 de septiembre de 2026.
--	--	--

Trabajo Adelantado: El proyecto ha superado significativamente la etapa inicial de viabilidad. Se ha confirmado: (1) Capacidad nativa de ejecución de LLMs (Gemma 2, DeepSeek, Llama) en Apple M4 mediante Ollama, sin necesidad de acelerador GPU externo, reduciendo costos de infraestructura; (2) Desarrollo de código Python standalone funcional para NER piloto en noticias públicas reales, demostrando concepto; (3) Integración inicial con Streamlit para visualización de resultados y con procesamiento batch para manejo de múltiples noticias; (4) Diseño preliminar de arquitectura RAG con mitigación de alucinaciones mediante context injection. Esta base técnica sólida permite enfoque en validación rigurosa y comparación entre modelos en la segunda mitad del proyecto.

IV. RECURSOS REQUERIDOS Y COMPROMISOS

La ejecución del proyecto requiere acceso a recursos técnicos, datos y apoyo institucional:

- **Hardware Disponible:** Estación de trabajo personal con Apple Silicon (MacBook Pro M4, 2024) con 16GB RAM y 512GB SSD. Este hardware es suficiente para ejecución local de modelos de 7B-14B parámetros mediante Ollama. Capacidad confirmada mediante pruebas piloto. Costo: Ya disponible (sin inversión adicional).
- **Software (Código Abierto):** Python 3.11+ (libre), Ollama (libre, open-source), Streamlit (libre), LangChain (libre), LlamaIndex (libre), Pandas (libre), Scikit-learn (libre), Matplotlib/Seaborn (libre). Costo total: \$0 (sin licencias requeridas).
- **Modelos de Lenguaje (Código Abierto):** Gemma 2 (Google, bajo Licencia Apache 2.0), DeepSeek (bajo Licencia MIT), Llama 2 (Meta, bajo Licencia Llama 2 Community). Todos son de acceso libre sin restricciones para investigación académica. Descargas y ejecución via Ollama. Costo: \$0.
- **Datos - Corpus de Noticias:** Acceso a base de datos de noticias de LeanStack SpA con historial de 2+ años de artículos recopilados de fuentes públicas (Google Alerts, CNN en Español, El Mercurio, Bloomberg Latin America, Reuters en Español). Datos contienen noticias de compliance, fraude financiero, sanciones. Compromiso de LeanStack SpA: Acceso garantizado bajo Acuerdo de Confidencialidad (NDA). Tamaño estimado: 10,000+ artículos disponibles (suficiente para seleccionar 100-150 de calidad para corpus de validación).
- **Expertise Humano - Anotadores Expertos:** Se requieren dos anotadores especialistas en compliance financiero para etiquetado del Ground Truth (Enero-Febrero 2026). Candidatos identificados: (1) Especialista 1: [Nombre por definir] con 5+ años en análisis de compliance en banco nacional; (2) Especialista 2: [Nombre por definir] con experiencia en RegTech. Compromiso de LeanStack SpA: Provisión de acceso a expertos internos para etiquetado.

Tiempo estimado: 40 horas por especialista (pagadas por LeanStack SpA, no generan costo adicional para proyecto).

- **Supervisión Académica y Orientación:** Profesor Guía: José Luis Martí Lara. Compromiso: Disponibilidad para reuniones bi-semanales (1 hora/sesión) y revisión de documentos de proyecto. Responsabilidades: Orientación técnica, validación de metodología, apoyo en arbitraje de desacuerdos de anotadores, feedback en redacción final. Disponibilidad confirmada.
- **Materiales Bibliográficos y Acceso a Literatura:** Acceso a arxiv.org (gratuito), IEEE Xplore (via suscripción institucional USM), Google Scholar (gratuito). Textos relevantes: "Attention Is All You Need" (Vaswani et al., open access), "BERT" (Devlin et al., open access), documentación oficial de LLMs (Llama, Gemma, DeepSeek - todas open access). Costo: \$0 (acceso académico).
- **Infraestructura de Versionamiento y Colaboración:** GitHub (repositorio privado para código, libre para estudiantes USM), Overleaf (para documentación colaborativa, plan académico gratuito). Costo: \$0.

Compromisos Explícitos:

- **Acuerdo de Confidencialidad (NDA):** LeanStack SpA requerirá NDA para proteger confidencialidad de datos de noticias y resultados de análisis. Clausulas incluirán: (a) No publicación de datos sin autorización; (b) Protección de identidad de clientes mencionados en noticias; (c) Restricción de acceso a documentos a solo coinvestigadores autorizados. NDA será entre estudiante, profesor guía y LeanStack SpA. Duración: 2 años post-finalización.
- **Compromiso de Disponibilidad de Contacto Industrial:** LeanStack SpA designará contacto responsable ([Por definir - Nombre, Cargo, Email, Teléfono]) disponible para: (a) Provisión

de datos de noticias; (b) Acceso a especialistas para etiquetado; (c) Feedback en validación de prototipo (máx 5 horas); (d) Revisión de capítulos de tesina relacionados con aplicación. Disponibilidad confirmada para duración del proyecto (Enero-Septiembre 2026).

- **Compromiso de Profesor Guía:** José Luis Martí Lara disponible para reuniones bi-semanales durante duración del proyecto y revision final. Señalará direcciones de investigación y asegurará rigor académico. Disponibilidad confirmada.