

Diseño de un sistema de clasificación de imágenes médicas a través de Deep Learning en entorno Cloud para proveer un servicio de diagnóstico de neumonía

Andrés Humberto Orozco Martínez
Sotraser SA
Américo Vespucio 14001, Santiago RM

`andres.oroazco@sotraser.cl`

Resumen: La neumonía es una de las patologías que más muertes causan en Chile. Para su detección, se necesitan especialistas en radiología y enfermedades broncopulmonares, los cuales son escasos. Además de enfrentarse a un gran flujo de radiografías a diario. Se planteó como solución en este trabajo crear un sistema de clasificación de imágenes médicas en un entorno *Cloud* utilizando sus *frameworks* de *Deep Learning*. Para diseñar la solución se probaron redes neuronales convolucionales y los *frameworks* de inteligencia artificial de plataformas *Cloud* usando *dataset* de imágenes de pacientes de neumonía públicos en la Web. A través de la comparación de las métricas de los modelos se pudo evidenciar que éstos mostraron confiabilidad a la hora clasificar y predecir las imágenes de pacientes de neumonía, discriminando correctamente a los con y sin enfermedad. Para la validación de los sistemas propuestos se realizaron dos experimentos, comparando las métricas de cada sistema propuesto en lo que respecta a clasificación de imágenes de pacientes con y sin enfermedad con las métricas de un especialista médico. Los resultados arrojaron que en ambos casos el modelo era capaz de igualar o superar la clasificación de imágenes de tórax de los pacientes, disminuyendo en el orden de 5 veces el tiempo de procesamiento. Estos resultados proyectan que de implementarse este tipo de sistemas en servicios de salud, se podría generar rápidos resultados y manejar un gran volumen de atenciones médicas por esta enfermedad reduciendo su mortalidad.

Palabras Clave: Deep Learning, Cloud Computing, telemedicina, neumonía, rayos X.

1 Introducción

1.1 Contexto, motivación y problemática

La atención de salud de los pacientes que habitan en zonas remotas del país se ha vuelto un foco de atención como política pública por el impacto socio económico que genera. La escasez de profesionales de medicina con especialidades deriva en alta mortalidad, baja calidad de vida y saturación de servicios de salud centrales debido a traslados de pacientes de centros de localidades que sólo cuentan con equipos de imagenología como rayos X y profesionales de medicina general. La neumonía es la tercera causa específica de muerte en la población chilena, siendo la primera causa de deceso en los mayores de 80 años [1].

El diagnóstico final requiere de exámenes de rayos X del pulmón realizados por especialistas radiólogo/broncopulmonar de baja presencia a nivel nacional [2].

1.2 Definición técnica del problema

El problema técnico, entonces, se define como el desarrollo de un sistema de apoyo a los médicos, que permita acelerar y aumentar la tasa de atención de pacientes con neumonía en lugares con dispersión geográfica de atención. Parte del trabajo será evaluar los rendimientos de los modelos en las distintas arquitecturas o *frameworks* usados.

En este contexto surge como alternativa la Telemedicina y la aplicación de las tecnologías de información como el *Deep Learning*, por sus altos rendimientos en clasificación de imágenes médicas a través de sus últimos avances en algoritmos de redes neuronales convolucionales y el *Cloud Computing* cuyas ventajas son la escalabilidad, el acceso remoto y un conjunto de *frameworks* a disposición para el desarrollo de estos sistemas como se abordará más adelante. El *Cloud* en este caso proporcionará el fácil acceso al sistema por parte de los especialistas médicos y su mantención.

1.3 Estrategia o enfoque de solución adoptado

La propuesta de solución consiste en el diseño de un sistema de clasificación de imágenes médicas a través de *Deep Learning* en entorno *Cloud*, para detección de pacientes con neumonía a través de análisis de radiografías de tórax.

Para el proceso de diseño de la solución, se consideran los siguientes objetivos:

- Desarrollar modelos con algoritmos de *Deep Learning* basado en Redes Neuronales Convolucionales que permitan identificar a pacientes con neumonía, analizando las imágenes de rayos X de tórax con una precisión de 92 % o superior y o F1 Score superior a 91 %.
- Evaluar y comparar la precisión en la clasificación de imágenes con plataformas de *Deep Learning* en *Cloud Computing* —como Amazon Rekognition de AWS, Cloud Giotto AI o Google Cloud AutoML—, con el propósito de seleccionar la mejor tecnología para construir la solución.
- Proponer una arquitectura de integración según los resultados anteriores, para proveer un servicio de clasificación de imágenes de rayos X en un entorno Cloud con los sistemas propios de procesamiento de imágenes de los servicios de Salud (RIS/PAC) en Chile.

1.4 Metodología de trabajo para la solución

Las etapas para abordar el trabajo serán las siguientes

1. Seleccionar como datos de entrada un set de imágenes de radiografía de tórax:
 - 5.232 imágenes de rayos X de tórax de niños [3].
 - 3.883 de esas imágenes son muestras de neumonía bacteriana (2.538) y viral (1.345)
 - 1.349 muestras son imágenes de rayos X pulmonares sanas.
 - Set de imágenes divididas en entrenamiento, testeo y validación.
2. Desarrollar un modelo de clasificación de imágenes a través de redes neuronales convolucionales en notebooks de Google Colab en lenguaje Python, utilizando bibliotecas de aprendizaje automático tensor Flow y Keras y junto con el paquete de librerías de scikit-learn.
 - Evaluar los resultados de clasificación, cambiar parámetros y volver a evaluar resultados.
3. Evaluar distintas arquitecturas de redes neuronales convolucionales para los modelos de clasificación de imágenes en plataformas *Cloud*, como Amazon Rekognition de AWS, Cloud Giotto ai o Google Cloud AutoML.
 - Cambiar parámetros y volver a evaluar resultados.
4. Elegir la plataforma *Cloud* con los mejores resultados de precisión de clasificación de imágenes.
5. El sistema desarrollado será testeado con datos reales de imágenes de rayos X de tórax, tanto de pacientes adultos como de pacientes pediátricos, contrastando los resultados del modelo con el diagnóstico de un especialista médico.
6. Finalmente, proponer una arquitectura de integración entre la plataforma elegida y los sistemas propios de procesamiento de imágenes de los servicios de Salud (RIS/PAC).

1.5 Estimación del impacto de implementación de la propuesta

Las proyecciones del trabajo realizado podrían tener el siguiente impacto:

- Tener a disposición de instalaciones de salud en el país un modelo de diagnóstico para el tratamiento de pacientes con síntomas de enfermedad de neumonía.
- Generar un aumento del volumen de atenciones médicas en servicios de salud para esta enfermedad.
- En ciudades con grandes volúmenes de pacientes con enfermedad, se podrá generar rápidos diagnósticos para el adecuado tratamiento y enfoque en aquellos que sí presentan la enfermedad de neumonía.

1.6 Hipótesis y método de validación

1.6.1 Hipótesis

En el desarrollo de una solución de diagnóstico médico para telemedicina, se propone la siguiente hipótesis:

- “El desarrollo de un sistema para clasificación de imágenes médicas a través de *Deep Learning* en entorno *Cloud* permitirá mejorar el diagnóstico médico de la enfermedad de neumonía, aumentando el volumen de radiografías diagnosticadas y reduciendo el tiempo de diagnóstico”.

1.6.2 Variables de Investigación

- **Variables independientes:** Datos de entrada /Modelos de Redes Neuronales Convolucionales /Interfaz de presentación del informe médico.
- **Variables dependientes:** Grado de precisión del Modelo.

1.6.3 Método de Validación

- Desarrollar un prototipo del sistema propuesto usando *Deep Learning* en una plataforma de *Cloud Computing*.
- Se evaluará las métricas de desempeño de los modelos en las plataformas *Cloud*.
- Se seleccionarán los modelos cuyos resultados sean superiores a 92 % de Precisión y/o F1score superior a 91 %
- Para la medición de los resultados se utilizará la matriz de confusión y las métricas *accuracy* y *F1 Score*. [3]
- Para la validación estadística de dichos resultados se utilizará validación cruzada. [4]
- Se realizará experimentos donde se comparará las métricas de desempeño en el diagnóstico de neumonía del sistema propuesto versus las métricas que resulten del diagnóstico de un especialista médico.

1.7 Estructura del informe

En el segundo capítulo se revisa el marco teórico y estado del arte de los conceptos claves que se utilizarán dentro de esta investigación.

En el tercer capítulo, se aborda el desarrollo de la metodología propuesta con los experimentos realizados y los resultados obtenidos. Se presenta una propuesta de visión arquitectónica del sistema, considerando la solución propuesta para dar respuesta a servicios de alta demanda.

Finalmente, se presenta una conclusión respecto de los resultados obtenidos, proponiendo consideraciones y próximos pasos a seguir.

2 Marco teórico y Estado del arte

Las bases de conocimiento de este trabajo se fundamentan en el *Deep Learning*, específicamente Redes Neuronales Convolucionales [4] y el *Cloud Computing* [5]. **Redes Neuronales Artificiales (ANN)**

2.1.1 Redes Neuronales modelo perceptrón

Las Redes Neuronales Artificiales (ANN) fueron diseñadas como modelos computacionales de neuronas humanas por el neurofisiólogo Warren McCulloch y el neurocientífico computacional Walter Pitts en el año 1943 y, al igual que el cerebro, se compone de las neuronas [6].




Figura 1. Esquema de neurona como perceptrón. Fuente: [7]

Las ANN se componen de nodos, que funcionan conectados unos a otros, formando una red. Esta red de nodos trabaja conjuntamente para estimar un resultado que se ajuste a un modelo no lineal con el mínimo error posible.

2.1.2 Redes Neuronales Convolucionales (CNN)

Las CNN corresponden al actual estado del arte para la clasificación de imágenes u objetos contenidos en ésta [8].

Este tipo de ANN está compuesto por una capa de entrada y una de salida, además de varias capas ocultas, algunas de las cuales son capas convolucionales con su función de activación, capas de *pooling* y capas totalmente conectadas (FC) con su función de activación, como se observa en la Figura 2.




Figura 2. Esquema general de CNN. Fuente [21, 17, 5]

2.2 Métricas del Deep learning

2.2.1 La Matriz de confusión [4]

Imagine que se tiene una prueba médica que verifica la presencia o ausencia de una enfermedad. Podemos utilizar un algoritmo de aprendizaje automático basado en clasificación; en este caso, con variables categóricas eligiendo una red neuronal convolucional. Existirán en la vida real dos posibles verdades: lo que se está probando es verdadero o no lo es ; es decir, la persona está enferma o no lo está.

Debido a esto, también hay dos resultados de prueba posibles: un resultado de prueba positivo (la prueba predice que la persona está enferma o no). Estas 4 opciones se resumen en el siguiente cuadro, debido a que surgen dos posibles valores reales y dos posibles valores de predicción o predictivos.



Figura 3. Matriz de Confusión. Fuente: [3]

Estas 4 opciones se conocen como la matriz de confusión. Veamos de nuevo esos 4 resultados posibles:

- **Verdadero positivo (VP):** El valor real es positivo y la prueba predijo también que era positivo. O bien una persona está enferma y la prueba así lo demuestra.
- **Verdadero negativo (VN):** El valor real es negativo y la prueba predijo también que el resultado era negativo. O bien la persona no está enferma y la prueba así lo demuestra.
- **Falso negativo (FN):** El valor real es positivo, y la prueba predijo que el resultado es negativo. La persona está enferma, pero la prueba dice de manera incorrecta que no lo está. Esto es lo que en estadística se conoce como error tipo II, esto considerando como verdaderos positivos que la imagen es neumonía.
- **Falso positivo (FP):** El valor real es negativo, y la prueba predijo que el resultado es positivo. La persona no está enferma, pero la prueba nos dice de manera incorrecta que sí lo está. Esto es lo que en estadística se conoce como error tipo I, lo anterior considerando al verdadero negativo a la imagen sin neumonía.

2.2.2 Métricas de la Matriz de confusión

A partir de estas 4 opciones mencionadas anteriormente, surgen las métricas de la matriz de confusión: por una parte, la Exactitud y la Precisión; y por otra, la Sensibilidad y la Especificidad.




Figura 4. Métricas derivadas de la matriz de confusión. Fuente: [3]

- **Exactitud (*Accuracy*):** se refiere a lo cerca que está el resultado de una medición del valor verdadero. En términos estadísticos, la exactitud está relacionada con el sesgo de una estimación. Se representa como la proporción de resultados verdaderos (tanto (VP) como (VN)) dividido entre el número total de casos examinados (verdaderos positivos, falsos positivos, verdaderos negativos y falsos negativos). En forma práctica, la exactitud es la cantidad de predicciones positivas que fueron correctas.

$$\text{Accuracy} = (\text{VP} + \text{VN}) / (\text{VP} + \text{FP} + \text{FN} + \text{VN})$$

- **Precisión (*Precision*):** Se representa por la proporción de verdaderos positivos dividido entre todos los resultados positivos (tanto verdaderos positivos, como falsos positivos). En forma práctica, la precisión es el porcentaje de casos positivos detectados.

$$\text{Precision} = \text{VP} / (\text{VP} + \text{FP})$$

- **Sensibilidad (*Recall*):** También se conoce como Tasa de Verdaderos Positivos (True Positive Rate) ó TP. Es la proporción de casos positivos que fueron correctamente identificadas por el algoritmo. En el área de la salud, se señala que la sensibilidad es la capacidad de poder detectar correctamente la enfermedad entre los enfermos.

$$\text{Recall} = \text{VP} / (\text{VP} + \text{FN})$$

Especificidad (*Specificity*): También conocida como la Tasa de Verdaderos Negativos, (True Negative Rate) o TN. Se trata de los casos negativos que el algoritmo ha clasificado correctamente. Expresa cuan bien puede el modelo detectar esa clase. En el área de la salud, se señala que la sensibilidad es la capacidad de poder detectar correctamente los pacientes sanos entre todos los sanos.

$$\text{Specificity} = \text{VN} / (\text{VN} + \text{FP})$$

- **F1-Score:** Esta es otra métrica muy empleada, porque nos resume la precisión y sensibilidad en una sola métrica. Por ello, es de gran utilidad cuando la distribución de las clases es desigual; por ejemplo, cuando el número de pacientes con una condición es del 15% y el otro es 85%, lo que en el campo de la salud es bastante común.

$$\text{F1score} = 2 * \text{Precision} * \text{Recall} / (\text{Precision} + \text{Recall})$$

2.3 Cloud Computing

Cloud Computing consiste en ofrecer servicios de computación a través de la red usando el almacenamiento en la nube [9]. Con este tipo de servicios, el usuario no tiene que instalar nada en su ordenador, no obstante, tendrá acceso a diferentes servicios. Entre sus ventajas, se mencionan las siguientes:

- Recursos flexibles: Aumentar o reducir los recursos de forma rápida y sencilla para cubrir la demanda.
- Servicio medido: Para que sólo pague lo que utilice.
- Autoservicio: Todos los recursos de TI que necesita con autoservicio.




Figura 5. Infraestructura de nube con proveedores (CSP) y clientes (CSC). Fuente: [9]

De forma resumida podríamos catalogar tres ejemplos de *Cloud Computing*:

- Infraestructura como Servicio (IaaS).
- Software como Servicio (SaaS).
- Plataforma como servicio (PaaS)




Figura 6. Computación en la nube organizada por recursos, modelos y ejemplo. Fuente: [9]

2.4 Trabajos relacionados

Al revisar diversas investigaciones y estudios relacionados previos para el desarrollo de esta tesina, se encontraron diversos artículos basados en el uso de redes neuronales en la detección de enfermedades; y en el caso específico de neumonía, utilizando para ello conjunto de datos de imágenes para poder realizar el entrenamiento de la red neuronal.

Para fines de orden y mejor comprensión se dividirá en tres líneas de investigación, a saber:

1. Redes Neuronales Convolucionales en el diagnóstico de imágenes médicas
2. Redes Neuronales Convolucionales en el diagnóstico de neumonía
3. Frameworks para desarrollo de Deep Learning en plataformas comerciales

2.4.1 Redes Neuronales Convolucionales en el diagnóstico de imágenes médicas

- Identifying Medical Diagnoses and Treatable Diseases by Image-Based Deep Learning [12]

En esta investigación se aborda la implementación de algoritmos de aprendizaje profundo con el objetivo de mejorar los actuales desafíos que se presenta en el campo de la medicina, respecto a la confiabilidad e interpretabilidad de diagnósticos de enfermedades comunes como son retinopatía y patologías respiratorias. Los resultados de su modelo tienen un promedio de precisión de 99 %. En este trabajo se comparó los resultados de los modelos con 6 expertos humanos. El mejor modelo de red neuronal convolucional arrojó una puntuación del 6,6% bajo este sistema de error ponderado. El error ponderado de los expertos varió de 0,4% a 10,5%, con un error ponderado promedio de 4,8%.

La relación de este estudio con este trabajo desarrollado señala el uso de las redes neuronales convolucionales como algoritmos apropiados para este propósito y la incorporación de expertos para comparar el desempeño de los modelos. El modelo usado en ese estudio pertenece al aprendizaje por transferencia y el algoritmo utilizado se usó para distintas enfermedades. A diferencia de esto, en esta tesina se abordará modelos específicos y entrenados para la enfermedad en cuestión.

2.4.2 Redes Neuronales Convolucionales en el diagnóstico de neumonía

- Pneumonia Detection Using CNN based Feature Extraction [10]

En este estudio los autores propusieron el desarrollo de un modelo predictivo para diagnosticar la neumonía, en base redes neuronales convolucionales para la clasificación de diversas características en imágenes radiográficas de tórax. Evaluaron en la investigación varios modelos de redes neuronales convolucionales pre-entrenados, tales como VGGNet, Xception, ResNet, AlexNet y DenseNet, para la clasificación de radiografías normales y anormales de tórax, y así poder detectar si se presentan casos potenciales de esta patología. Como conclusiones determinan que el uso y combinación de arquitecturas y técnicas de clasificación de imágenes aumentan los márgenes de obtener mejores resultados en el diagnóstico de enfermedades como la neumonía. La relación de este estudio con la tesina confirma el uso de CNN para abordar la problemática de la enfermedad en cuestión. Plataformas *Cloud* y telemedicina. En este trabajo no se analizaron todas las arquitecturas ya que, de acuerdo con la revisión del estado del arte en CNN, las actuales con mejor rendimiento, corresponden a *ResNet* y *EfficientNet*.¹

- Clasificación de imágenes médicas con SageMaker y Tensorflow2 [11]

Esta publicación desarrolla un modelo de clasificación de imágenes médicas, para implementarlo y consumirlo en tiempo real utilizando el SDK de SageMaker de la nube AWS.

A diferencia de los otros estudios, en este caso se hace uso específico de las ventajas de los *frameworks* de *Deep learning* usando SageMaker. Como consecuencia, la relación con el trabajo desarrollado tiene que ver con explorar y analizar la implementación de sistema de clasificación haciendo uso de estos *frameworks* y obteniendo las ventajas de *Cloud Computing* ya señaladas anteriormente.

¹ <https://theaisummer.com/cnn-architectures/>

2.4.3 Frameworks para desarrollo de Deep Learning en plataformas comerciales

a. Amazon rekognition (AWS) [12]

Amazon Rekognition se basa en la misma tecnología de aprendizaje profundo de eficacia demostrada y altamente escalable desarrollada por los científicos de visión por computador de Amazon para analizar miles de imágenes y vídeos al día. No requiere experiencia en aprendizaje automático.

b. Google cloud vertex AI AutoML (Google) [13]

- **Vertex AI:** Plataforma unificada que ayuda a desarrollar, desplegar y escalar más modelos de inteligencia artificial.
- **AutoML image:** Extrae información valiosa de los datos de detección de objetos y clasificación de imágenes, en la nube.

c. cloud.giotto.ai [14]

Esta es una plataforma catalogada como *Low Code*; esto es que permite ser usada por personas no especialistas en el área de la inteligencia artificial o ciencia de datos. Es una plataforma mejorada por el Análisis de Datos Topológicos (TDA), capaz de agrupar observaciones de una manera no supervisada y sin modelo, creando representaciones de baja dimensión que no deforman la forma de alta dimensión de la nube de puntos original.

3 Desarrollo de la solución

3.1 Desarrollo de Modelo de clasificación de imágenes a través a través de redes neuronales convolucionales en notebook de Google Colab.

Fuente de datos: <https://www.kaggle.com/paultimothymooney/chest-xray-pneumonia/version/2> [3]

- Los datos están compuestos por 3 set de imágenes de radiografías, 5.846 imágenes (1,2 GB).
- Entrenamiento, testeo y validación. Radiografías de pacientes con neumonía y sin dicha enfermedad.

Para este experimento se trabajó con CNN, dado sus altos rendimientos en clasificación de imágenes. Se utiliza lenguaje de programación *Python*, y dentro de éste se utilizaron las librerías tensorflow, Keras y el paquete de librerías de scikit-learn.

Del análisis exploratorio de los datos, se realizó un balance de las imágenes de entrenamiento dejando en igual cantidad las imágenes de neumonía y normales (1.343); esto para evitar un sesgo en el aprendizaje de la red (ver Figura 7).




Figura 7. Comparación de composición del set de imágenes reales vs el balanceo para entrenamiento.




Figura 8. Muestra de imágenes de entrenamiento balanceados en código Python.

Se configuró una CNN con 4 capas. Para las capas internas se utilizó la función de activación “Relu”, y para la capa de salida Softmax. La red se hizo pasar por 64 Filtros 3x3 dim y un “maxpooling” de dimensión 2X2 dim. (ver Figura 9)

```
model = models.Sequential()

model.add(layers.Conv2D(64, (3, 3), activation='relu', input_shape=(150, 150, 1)))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Conv2D(64, (3, 3), activation='relu'))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Conv2D(64, (3, 3), activation='relu'))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Conv2D(64, (3, 3), activation='relu'))

model.add(layers.Flatten())
model.add(layers.Dense(64, activation='relu'))
model.add(layers.Dense(2, activation='softmax'))

model.summary()
```

Figura 9. Configuración Red neuronal convolucional.

Para la compilación del Modelo se utilizó el optimizador “ADAM” y, como función de pérdida “sparse_categorical_crossentropy”, (ver Figura 10).

```
model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])

log_dir="logs/fit/" + datetime.datetime.now().strftime("%Y%m%d-%H%M%S")
tensorboard_callback = tf.keras.callbacks.TensorBoard(log_dir, histogram_freq=1)

history = model.fit(X_trainReshaped,
                    y_train, |
                    epochs=20,
                    validation_data = (X_testReshaped,y_test),
                    callbacks=[tensorboard_callback])
```

Figura 10. Compilación Modelo.

Se realizaron 20 épocas (veces en que se hace correr el modelo por la red neuronal) y se midieron las métricas *Accuracy*, *Precision*, *Recall* y *F1score* como se observa en la Figura 11.

```
CONFUSION MATRIX -----
[[214  18]
 [ 18 372]]

TEST METRICS -----
Accuracy: 94.21221864951768%
Precision: 95.38461538461539%
Recall: 95.38461538461539%
F1-score: 95.38461538461537

TRAIN METRIC -----
Train acc: 98.32
```

Figura 11. métricas del modelo.

Para el grupo de prueba los resultados sobrepasaron los 94 % en todas las métricas, lo que confirma a las redes neuronales convolucionales como algoritmos apropiados para utilizar en esta clase de modelos.

A continuación, se muestran los desarrollos de los modelos de clasificación de radiografías de tórax en tres plataformas comerciales distintas. La cantidad de imágenes y particiones para entrenamiento y prueba para las plataformas presentan variedad, debido a la dificultad práctica para la carga de datos en los modelos, por lo que se optó por la combinación de datos que optimizara los tiempos para carga y procesamiento.

3.2 Sistema de clasificación de imágenes de radiografía de Tórax para diagnóstico de neumonía en plataforma Amazon rekognition

A continuación, se muestra el desempeño del framework Rekognition de AWS [12] para el problema propuesto.

En la Figura 12 se muestra el data set propuesto [3], donde se observa que el set se ha dividido en 2134 imágenes para el entrenamiento del modelo y 535 para el testeo de éste.

Las métricas del modelo implementado en el data set de prueba se muestran en la Figura 13. Se destaca el alto valor de F1 Score y precisión de 99,6 % lo que señala a este tipo de framework como una buena solución para el desarrollo del sistema de clasificación de imágenes médicas.




Figura 12. Métricas del modelo implementado.

Amazon Rekognition también ofrece visualizar los tipos de errores que se cometieron en la clasificación de imágenes médicas, tal como se observa en la Figura 14. Este tipo de información es útil para depurar los algoritmos y entender qué tipos de imágenes requieren mayor análisis previo antes de la clasificación.

En la Figura 14, la imagen de la izquierda representa una imagen de rayos X normal, que fue catalogada como neumonía por el modelo, mientras que la imagen de la derecha corresponde a una imagen de rayos X de un paciente con neumonía viral, que el modelo clasificó erróneamente como normal.




Figura 13. Tipo de errores encontrados en la clasificación del modelo.

3.3 Sistema de clasificación de imágenes de radiografía de tórax para diagnóstico de neumonía en plataforma Google Cloud Vertex AI AutoML

A continuación, se muestran los resultados usando el *framework* de Google Cloud Vertex [13]. En la Figura 15 se muestran las imágenes.




Figura 14. Imágenes de los datos de entrenamiento para el modelo.

En la Figura 16 se muestran las métricas del modelo.




Figura 15. Métricas de desempeño del Modelo.

Para entender cómo AutoML obtiene los valores de precisión y sensibilidad (*Recall*), se debe considerar lo siguiente:

- Los valores de verdaderos positivos, falsos positivos y falsos negativos utilizados para calcular la precisión y el *recall* no son los que se muestran en la matriz de confusión.
- Los valores utilizados se generaron teniendo en cuenta el valor umbral y la puntuación de confianza de cada imagen de prueba para cada clase diferente.
- Las cantidades reportadas en la matriz de confusión se calculan usando *argmax* con los valores de confianza de cada imagen.
- No hay influencia del valor umbral en la matriz de confusión mostrada. Esto también explica por qué la matriz de confusión permanece estática, incluso si cambia el umbral.

En atención a lo anterior, se ha optado por obtener las métricas totales de desempeño a través de la matriz de confusión (Figura 17).



Figura 16. Matriz de confusión como resultado del Modelo AutoML.

Las métricas se resumen en la Tabla 1. Para cada una de las métricas se observan alto valores, lo que confirma al modelo como una buena alternativa para el desarrollo del sistema de clasificación.

Tabla 1. métricas de desempeño del modelo en base a resultados de matriz de confusión

Métrica	Valor
Precision	94,2%
Recall	97,7 %
Accuracy	95,8 %
F1-Score	95,9 %

En la Figura 18, se muestra el despliegue del modelo para predicción de cualquier imagen que se le cargue. AutoML también tiene la opción de realizar procesos *batch* de predicción.



Figura 17. Resultado de predicción de una imagen.

3.4 Sistema de clasificación de imágenes de radiografía de tórax para diagnóstico de neumonía en plataforma cloud.giotto.ai

El set de datos utilizado como prueba es el ya estudiado anteriormente [3], la distribución de los datos se muestra en la Figura 19. A diferencia del *data set* anterior, esta muestra se ha analizado tal como existe, es decir desbalanceada en sus categorías normal (4683) y neumonía (1170).

dataset	total samples	split %	size
training dataset	4683	80.0	992.0 MB
validation dataset	1170	20.0	248.0 MB
total	5853	100.0	1.24 GB

dataset	class: NORMAL	class: PNEUMONIA	total samples
training dataset	1253	3430	4683
validation dataset	327	843	1170
total	1580	4273	5853

Figura 18. Data set de imágenes ocupados para el modelo.

Cloud.giotto.ai trabaja con un tipo específico de redes CNN llamadas ResNet. Esta es una red usada como elemento básico en muchas tareas de Visión por Computadora. Este algoritmo llamado redes residuales donde el índice indica el número de capas profundas que posee la CNN, fue la red ganadora de la competencia (challenge) ImageNet en 2015.² Giotto permite elegir configuraciones de ResNet desde resnet18 hasta resnet152, donde el número indica la cantidad de capas profundas. Para efectos de balancear tanto el rendimiento del algoritmo como el tiempo de procesamiento y recursos se optó por un ResNet de 50 capas como se observa en la Figura 20.

architecture	base model	size	best epoch	max epochs
CNN	resnet50	102.46 MB	17	20

Figura 19. Arquitectura de la CNN utilizada para el modelo.

En la Figura 21 se observa que el mayor rendimiento de *Accuracy* se dio en la época 17. Del gráfico de pérdida, se observa que el modelo tiene rendimiento comparable en ambos conjuntos de datos.




Figura 20. Métricas de rendimiento del modelo y pérdida por número de épocas.

A través de los datos de la matriz de confusión generada (Figura 22), podemos obtener las métricas de la tabla 2.

² http://personal.cimat.mx:8181/~mriviera/cursos/aprendizaje_profundo/resnet/resnet.html

		Predicted class	
		NORMAL	PNEUMONIA
True class	NORMAL	313	14
	PNEUMONIA	12	831

Figura 21. Matriz de Confusión como resultado del modelo.

Tabla 2. Métricas del modelo en base a resultados de matriz de confusión

Métrica	Valor
Precision	98,3 %
Recall	98,6 %
Accuracy	97,8 %
F1-Score	98,5 %

Giotto ofrece también poder visualizar las imágenes que fueron clasificadas erróneamente tal como se observan en la Figura 23.




Figura 22. Imágenes con error en la clasificación.

3.5 Evaluación de la precisión en el diagnóstico de neumonía a través de clasificación de imágenes médicas mediante modelos de Deep Learning y su comparación con el criterio de especialista médico broncopulmonar

3.5.1 Explicación de los experimentos

Con el objeto de probar la validez de los modelos y su poder de diagnóstico, se ha procedido a comparar las métricas resultantes de clasificación de éste [15] versus el diagnóstico de las mismas imágenes realizadas por

un experto médico. Como experto médico, se ha elegido a una especialista en el estudio de la neumonía [16], doctora en Medicina Broncopulmonar ³.

Se revisaran dos set de datos de imágenes de rayos X, un set de imágenes de pacientes adultos [17] y un set de imágenes de pacientes pediátricos [3]. Cada uno estará compuesto por 24 imágenes de rayos de pacientes con sospecha de neumonía y el objetivo es comparar las métricas en el diagnóstico y evidenciar el tiempo de clasificación de éstas.

3.5.2 Evaluación con set de imágenes de rayos X de pacientes adultos

3.5.2.1 Conjunto de datos y modelo ocupados

Para efectos del modelo, se utilizaron 419 imágenes. Para este experimento se utilizó el *framework* Vertex AutoML [16].

En la Figura 24, se muestra el set de datos que conforma el conjunto para entrenamiento. De éstas, 419 imágenes 243 son normales y 176 corresponden a neumonía.



Figura 23. Set de imágenes médicas para entrenamiento.

Los resultados del modelo entrenado en Vertex AutoML se muestran en la Figura 25.



Figura 24. Métricas del modelo con el cual se realizará el experimento.

³ Médico Cirujano: Universidad de Valparaíso Especialidad: Broncopulmonar; Subespecialidad: Neumología.
Postgrado: Enfermedades respiratorias y alérgicas PUC.
Pertenencia: Sociedad Chilena de enfermedades Respiratorias.

En la tabla 3 se muestran las métricas de desempeño en base a la matriz de confusión según Figura 25. Se observa que, pese a que no se trabajó con un conjunto grande de datos, Vertex AutoML es capaz de generar altos rendimientos de clasificación.

Tabla 3 -Métricas del modelo en base a resultados de matriz de confusión

Métrica	Valor
Precisión	88,9 %
Recall	94,1 %
Accuracy	92,7 %
F1-Score	91,4 %

3.5.2.2 Desarrollo del Experimento

Se han seleccionado aleatoriamente 24 imágenes del set de datos para ser evaluadas (Figura 26). Previamente se han caracterizado por código y su etiqueta real (neumonía /normal) para su posterior comparación por el especialista Médico.

Para el conjunto de datos de 24 imágenes, tanto el modelo como el diagnóstico del especialista médico acertaron en un 100 %, tal como se observa en la tabla 4.

Tabla 4 Comparación de resultados de clasificación/diagnóstico de imágenes médicas modelo Deep Learning Cloud vs Criterio del especialista

Métrica	Modelo IA	Criterio Especialista
Precisión	100%	100%
Recall	100%	100%
Accuracy	100%	100%
F1 Score	100%	100%
Tiempo de Procesamiento (minutos)	0:40	3:32

Se destaca la velocidad de procesamiento de la información entre ambos. Mientras el modelo tardó 40 segundos en procesar y entregar el resultado, el especialista médico tardó 3 minutos y 32 segundos. Esta información es de particular importancia cuando se habla de escalamiento y de altos volúmenes de carga de datos.




Figura 25. Imágenes para probar el modelo.

3.5.3 Evaluación con set de imágenes de rayos X de pacientes Pediátricos

3.5.3.1 Conjunto de datos y modelo ocupados

El conjunto de datos es el estudiado previamente en la sección 3.4.



Figura 26. Set de imágenes médicas para entrenamiento. [3]

Como plataforma se ha utiliza la plataforma Cloud Giotto.ai y el modelo explicado en el punto 3.4, por lo que se consideran sus mismas métricas.

3.5.3.2 Desarrollo del Experimento

En la tabla 5 se muestran los resultados del experimento con datos de pacientes pediátricos.

Tabla 5 Comparación de resultados de clasificación/diagnóstico de imágenes médicas: modelo Deep Learning- Cloud vs criterio del especialista médico.

Métrica	Modelo IA	Criterio del especialista
Precision	80 %	60 %
Recall	100%	100%
Accuracy	87,5 %	66.7 %
F1 Score	88, 9%	75 %
Tiempo de Procesamiento (minutos)	1:00	5:14

Para este conjunto de datos sí se observó diferencias entre la clasificación del modelo IA y el criterio del especialista médico, obteniendo mejores métricas el modelo IA.

Para ambos casos, se clasificó erróneamente imágenes normales como si fuesen de pacientes con neumonía; es decir, se generaron falsos positivos, siendo en mayor proporción en el caso del especialista médico.

Se destaca que en ambos casos el *recall* es de un 100 %. Esto es de gran importancia, ya que el *recall* es la métrica que da indicio del error tipo 2; es decir, que un paciente con neumonía real sea identificado o clasificado como normal y, en consecuencia, con el riesgo de no ser tratado medicamente.

En cuanto al tiempo de procesamiento, el modelo IA tiene un menor tiempo del orden de 5 veces respecto al médico; y en este caso, con mejor precisión.

3.6 Arquitectura de integración entre las plataformas elegidas y los sistemas propios de procesamiento de imágenes de los servicios de Salud (RIS/PAC).

A continuación, se propone dos arquitecturas en las plataformas principales de *Cloud Computing*, que podrían ser alternativas para la implementación de la propuesta de esta tesis una vez resuelto la ley de protección de datos y validada la interoperabilidad de los sistemas de salud en Chile⁴.

3.6.1 Arquitectura de integración en plataforma Google Cloud con la API de healthcare

El siguiente diagrama representa una arquitectura de línea base para la integración de datos FHIR, HL7v2 y DICOM. Muestra tres patrones de integración [18]:

- Uso de un motor de integración como Cloverleaf o NextGen Connect (anteriormente Mirth Connect). Cloverleaf ofrece el fundamento de integración clínica para los profesionales de la salud, HIE, ACO, laboratorios y fabricantes de dispositivos médicos y de aplicaciones (ISV y OEM). La plataforma también acepta la virtualización de implementaciones en la nube privada y pública, y aprovecha los mecanismos de conmutación por error y disponibilidad. Esto puede ser apropiado para datos FHIR y HL7v2.
- Uso directo del adaptador MLLP de la API de Cloud Healthcare para reenviar datos a la API HL7v2 de Cloud Healthcare.
- Ingesta de datos de imágenes DICOM de un sistema PACS o archivo independiente del proveedor.




Figura 27 : Arquitectura de integración propuesta para el análisis de imágenes médicas e integración con sistemas RIS/PACS. [18]

Cada tipo de datos pasa por tres fases: ingesta, limpieza / filtrado / transformación y procesamiento. Los detalles de cada paso, sin embargo, difieren un poco dependiendo de la modalidad de datos.

⁴ <https://blog.continuumhq.com/3-grandes-retos-para-alcanzar-la-interoperabilidad-en-salud-en-chile>

3.6.2 Arquitectura de integración en plataforma AWS

Los sistemas de archivo y comunicaciones de imágenes (PACS) se utilizan ampliamente para almacenar y administrar imágenes médicas y metadatos relacionados. Estos sistemas son fundamentales para compartir imágenes entre los equipos médicos modernos que colaboran en la atención al paciente. Además, los investigadores y los médicos pueden acceder a las imágenes de PACS y verlas en una estación de trabajo en un consultorio o clínica. Estos usuarios finales (médicos, radiólogos, investigadores y operadores remotos) requieren entornos de TI que sean fácilmente accesibles y que puedan escalar automática y globalmente bajo demanda.

La red de profesionales involucrados en la gestión y revisión de imágenes está ampliamente distribuida; sin embargo, las aplicaciones para revisión y análisis todavía están basadas en gran medida en escritorio. Esto significa que un caso de uso común para la industria de la salud es usar aplicaciones de escritorio desde cualquier lugar. Una alternativa es el uso en el que AppStream 2.0 como la Figura 29.




Figura 28 Arquitectura de integración propuesta para el análisis de imágenes médicas e integración con sistemas RIS/PACS [3].

4 Conclusiones y Recomendaciones

Las redes neuronales convolucionales probaron ser un algoritmo confiable para la clasificación de imágenes médicas de neumonía, en este caso para rayos X de tórax. Estos algoritmos fueron probados tanto a nivel local en el modelo desarrollo en código Python como en la plataforma Cloud Giotto.ai, la cual usaba un tipo específico de red neuronal llamada ResNet.



Los *framework* de Deep Learning en plataformas Cloud como Amazon Rekognition y Google Cloud AutoML, al ser del tipo caja negra, no es posible asegurar que usan este tipo de algoritmo; sin embargo, de igual forma resultaron ser confiables a la hora de la predicción de la enfermedad con métricas superiores al 92 %.

Los experimentos realizados para la comparación, entre la precisión lograda en la clasificación de las imágenes de los modelos versus el especialista médico, entregaron las siguientes conclusiones:

- Es preferible que los modelos se entrenen con el tipo específico de imágenes que procesarán. Es decir, si el algoritmo procesará imágenes de pacientes niños, adultos o de tercera edad, el conjunto de datos de entrenamiento y prueba deben ser consistentes con ese grupo etario.
- Los dos *frameworks* de Deep Learning con los que se hicieron los experimentos entregaron igual o mejor predicción de la enfermedad que el especialista médico.
- Los dos *frameworks* de Deep Learning con los que se realizaron los experimentos entregaron resultados en menor tiempo del orden de las 5 veces comparado con el especialista médico. Lo anterior es particularmente importante, ya que precisamente se postula al *Cloud Computing* como una ventaja a la hora de procesar datos de mayores volúmenes y en sistemas distribuidos de telemedicina.
- Se intentó buscar una propuesta de integración de la solución en la nube con los sistemas actuales de salud. Sin embargo, dada las actuales restricciones de seguridad de datos y política por aprobar de sistemas de interoperabilidad, no se pudo realizar como se había propuesto inicialmente, resumiendo sólo una propuesta de arquitectura de integración con los *frameworks* utilizados.
- Se debe considerar que, al no tener una muestra de especialistas médicos mayor, los resultados no pueden ser generalizados. Sin embargo, se establece una metodología de trabajo para ampliarlo.
- Como medida de seguridad debe haber un proceso de cifrado criptográfico de la información en una nube privada, con control de acceso de los usuarios.

Por lo anterior, la hipótesis respecto a que el desarrollo de un sistema para clasificación de imágenes médicas a través de Deep Learning en entorno Cloud puede mejorar el diagnóstico médico de enfermedad neumonía en forma remota, se valida específicamente en lo que es mayor exactitud y tiempo de clasificación.

5 Trabajos Futuros

Actualmente está pendiente la regulación de la interoperabilidad y seguridad de datos para la investigación a nivel nacional en el área de datos de la salud. Los actuales esfuerzos de instituciones como el Centro Nacional en sistemas de información de salud están en desarrollar las tecnologías de interoperabilidad y anonimización de datos de pacientes, para poder trabajar con éstos en áreas de investigación y desarrollo y mejorar en los servicios de telemedicina. Se han logrado avances importantes en proyectos como ALPACS health data 4 Mining⁵.

En ese contexto, un posible trabajo futuro será la prueba de estos sistemas con datos reales de pacientes en Chile y hacer pruebas piloto, ya sea en procesos *batch* o continuos en conjunto con un grupo de especialista médicos heterogéneos para la monitorización de los resultados.

⁵ Repositorios de Información Interoperables para la Minería de Datos en la Industria de la Salud; FONDEF IDeA I+D 2019 (2019-2021), Universidad Técnica Federico Santa María, Universidad de Chile.

6 Referencias

- [1] G. Valdivia C., «Epidemiología de la neumonía del adulto adquirida en la comunidad,» *Revista chilena de enfermedades respiratorias*, vol. 21, n° 2, pp. 73-80, 2005.
- [2] Subsecretaría de redes Asistenciales, «Estudio de brechas de oferta y demanda de médicos especialistas,» Ministerio de Salud, Gobierno de Chile, Santiago, Chile, 2010.
- [3] P. Mooney, «chest-xray-pneumonia version,» 2022. [En línea]. Available: <https://www.kaggle.com/paultimothymooney/chest-xray-pneumonia/version/2..>
- [4] J. Barrios, «Redes Neuronales Convolucionales,» 2020. [En línea]. Available: <https://www.juanbarrios.com/redes-neurales-convolucionales>.
- [5] AWS, «Aprendizaje profundo en AWS,» 2021. [En línea]. Available: <https://aws.amazon.com/es/deep-learning>.
- [6] E. Varela Arregocés y C. S. Edwin, «Redes Neuronales Artificiales: Una Revisión del estado del arte, aplicaciones y tendencias futuras,» *investigación y Desarrollo en TIC*, vol. 2, n° 1, pp. 18-27, 2011.
- [7] D. S. .EU, «Aprendizaje Automático: ¿Perceptrón?,» 2020. [En línea]. Available: <https://datascience.eu/es/aprendizaje-automatiko/perceptron>.
- [8] C. Pérez Lorenzo, «Detección precoz de Cáncer de piel en imágenes basado en redes convolucionales,» Trabajo de Grado, Universidad Autónoma de Madrid, Madrid, España, 2019.
- [9] F. A. Paliza, «Las Redes Futuras y la virtualización de las funciones de Red,» *IEEE NOMS*, pp. 10-11, 2016.
- [10] D. Varshni, K. Thakral, L. Agarwal, R. Nijhawan y A. Mittal, «Pneumonia Detection Using CNN based Feature Extraction,» de *2019 IEEE International Conference on Electrical, Computer and Communication Technologies (ICECCT)*, Coimbatore, India, 2019.
- [11] M. Gaska, «Clasificación de imágenes médicas con SageMaker y Tensorflow2,» 2020. [En línea]. Available: <https://aws.amazon.com/es/blogs/aws-spanish/clasificacion-de-imagenes- medicas-con-sagemaker-y-tensorflow2>.
- [12] AWS, «¿Qué es Amazon Rekognition?,» 2022. [En línea]. Available: https://docs.aws.amazon.com/es_es/rekognition/latest/dg/what-is.html.
- [13] T. R. Weiss, «Easing Machine Learning for Developers, Google's Vertex AI Managed ML Platform Now Available,» 2021. [En línea]. Available: <https://www.enterpriseai.news/2021/05/19/easing-machine-learning-for-developers-googles-vertex-ai-managed-ml-platform-now-available/>.
- [14] Giotto, «Stop coding. Start AI,» 2020. [En línea]. Available: <https://cloud.giotto.ai/>.
- [15] J. Barrios, «La Matriz de Confusión y sus métricas,» [En línea]. Available: <https://www.juanbarrios.com/la-matriz-de-confusion-y-sus-metricas>.
- [16] M. Barros M., C. Cartagena S. y L. Bavestrello F., «Prevención de la neumonía adquirida en la comunidad,» *Revista chilena enfermedades respiratorias*, vol. 21, n° 5, pp. 133-140, 2005.
- [17] National Institutes of Health, «NIH Clinical Center provides one of the largest publicly available chest x-ray datasets to scientific community,» 27 September 2017. [En línea]. Available: <https://www.nih.gov/news-events/news-releases/nih-clinical-center-provides-one-largest-publicly-available-chest-x-ray-datasets-scientific-community>.
- [18] C. v. See, «Introducción a la API de Google Cloud Healthcare,» 2018. [En línea]. Available: <https://cloud.google.com/blog/topics/healthcare-life-sciences/getting-to-know-the-google-cloud-healthcare-api-part-3>.
- [19] J. Amat Rodrigo, «Validación de modelos predictivos: Cross-validation, OneLeaveOut, Bootstrapping,» 2020. [En línea]. Available: https://www.cienciadedatos.net/documentos/30_cross-validation_oneleaveout_bootstrap.



- [20] C. Fuller, H. Kaur y P. Shetty, «Uso de AppStream 2.0 para ofrecer PACS y análisis de imágenes en ensayos clínicos,» 2017. [En línea]. Available: <https://aws.amazon.com/es/blogs/architecture/using-appstream-2-0-to-deliver-pacs-and-image-analysis-in-clinical-trials/>.
- [21] Machine Intellegence, «CNN-Convolution Neural Network,» 15 May 2018. [En línea]. Available: <http://www.machineintelligence.com/cnn-convolution-neural-network/>.
- [22] D. S. Kermany y otros, «Identifying Medical Diagnoses and Treatable Diseases by Image- Based Deep Learning,» *Cell*, vol. 172, nº 5, pp. 1122-1131, 2018.

Anexos

I. Resultados predicción experimentos Set de imágenes de paciente adultos

i. Valores de predicción Modelos vs Criterio Especialista

File name	NORMAL	PNEUMONIA	Predicted class	Real Class	Criterio Especialista
IM-0001.jpeg	0,964	0	NORMAL	NORMAL	NORMAL
IM-0002.jpeg	0,019	0,948	NEUMONIA	NEUMONIA	NEUMONIA
IM-0003.jpeg	0,04	0,909	NEUMONIA	NEUMONIA	NEUMONIA
IM-0004.jpeg	0,023	0,938	NEUMONIA	NEUMONIA	NEUMONIA
IM-0005.jpeg	0,761	0,122	NORMAL	NORMAL	NORMAL
IM-0006.jpeg	0,077	0,824	NEUMONIA	NEUMONIA	NEUMONIA
IM-0007.jpeg	0,884	0,045	NORMAL	NORMAL	NORMAL
IM-0008.jpeg	0,977	0	NORMAL	NORMAL	NORMAL
IM-0009.jpeg	0,898	0,039	NORMAL	NORMAL	NORMAL
IM-0010.jpeg	0,018	0,955	NEUMONIA	NEUMONIA	NEUMONIA
IM-0011.jpeg	0,019	0,952	NEUMONIA	NEUMONIA	NEUMONIA
IM-0012.jpeg	0,024	0,939	NEUMONIA	NEUMONIA	NEUMONIA
IM-0013.jpeg	0,031	0,927	NEUMONIA	NEUMONIA	NEUMONIA
IM-0014.jpeg	0,915	0,03	NORMAL	NORMAL	NORMAL
IM-0015.jpeg	0,019	0,95	NEUMONIA	NEUMONIA	NEUMONIA
IM-0016.jpeg	0,984	0	NORMAL	NORMAL	NORMAL
IM-0017.jpeg	0,019	0,951	NEUMONIA	NEUMONIA	NEUMONIA
IM-0018.jpeg	0,945	0,018	NORMAL	NORMAL	NORMAL
IM-0019.jpeg	0,959	0	NORMAL	NORMAL	NORMAL
IM-0020.jpeg	0,979	0	NORMAL	NORMAL	NORMAL
IM-0021.jpeg	0,015	0,963	NEUMONIA	NEUMONIA	NEUMONIA
IM-0022.jpeg	0,014	0,966	NEUMONIA	NEUMONIA	NEUMONIA
IM-0023.jpeg	0,903	0,037	NORMAL	NORMAL	NORMAL
IM-0024.jpeg	0,888	0,044	NORMAL	NORMAL	NORMAL

ii. Matriz de Confusión Modelo

VP	FP	12	0	Imágenes con neumonía correctamente clasificadas	Imágenes "Normales" clasificadas como "Neumonía"
FN	VN	0	12	Imágenes con neumonía clasificadas como "Normales"	Imágenes "Normales" correctamente clasificadas

iii. Matriz de Confusión Especialista

VP	FP	12	0	Imágenes con neumonía correctamente clasificadas	Imágenes "Normales" clasificadas como "Neumonía"
FN	VN	0	12	Imágenes con neumonía clasificadas como "Normales"	Imágenes "Normales" correctamente clasificadas

II. Resultados Experimentos set de imágenes de pacientes pediátricos

i. Valores de predicción Modelos vs Criterio Especialista

File name	NORMAL	PNEUMONIA	Predicted class	Real Class	Criterio Especialista
IM-0001.jpeg	0.9993252754211426	0.0006747461738996208	NORMAL	NORMAL	NORMAL
IM-0002.jpeg	0.9988905787467957	0.0011094212532043457	NORMAL	NORMAL	NORMAL
IM-0003.jpeg	0.9999985694885254	0.0000014552791753885685	NORMAL	NORMAL	NEUMONIA
IM-0004.jpeg	0.9999585151672363	0.00004151546090724878	NORMAL	NORMAL	NEUMONIA
IM-0005.jpeg	1,00	0,00	NORMAL	NORMAL	NEUMONIA
IM-0006.jpeg	0.4459269344806671	0.5540730357170105	PNEUMONIA	NORMAL	NEUMONIA
IM-0007.jpeg	0.26523658633232117	0.7347634434700012	PNEUMONIA	NORMAL	NEUMONIA
IM-0008.jpeg	1,00	0,00	NORMAL	NORMAL	NORMAL
IM-0009.jpeg	1,00	0,00	NORMAL	NORMAL	NEUMONIA
IM-0010.jpeg	1,00	0,00	NORMAL	NORMAL	NORMAL
IM-0011.jpeg	0.996113657951355	0.0038863015361130238	NORMAL	NORMAL	NEUMONIA
IM-0012.jpeg	0.2680269479751587	0.7319731116294861	PNEUMONIA	NORMAL	NEUMONIA
IM-0013.jpeg	0.0007985050906427205	0.9992014765739441	PNEUMONIA	PNEUMONIA	NEUMONIA
IM-0014.jpeg	0.000653292634524405	0.9993466734886169	PNEUMONIA	PNEUMONIA	NEUMONIA
IM-0015.jpeg	0.0003230084839742630	0.9996770620346069	PNEUMONIA	PNEUMONIA	NEUMONIA
IM-0016.jpeg	0.0001701056462479755	0.999829888343811	PNEUMONIA	PNEUMONIA	NEUMONIA
IM-0017.jpeg	0.0006103110499680042	0.9993896484375	PNEUMONIA	PNEUMONIA	NEUMONIA
IM-0018.jpeg	0.0004253252991475165	0.9995747208595276	PNEUMONIA	PNEUMONIA	NEUMONIA
IM-0019.jpeg	0.011958371847867966	0.9880416393280029	PNEUMONIA	PNEUMONIA	NEUMONIA
IM-0020.jpeg	0.018907444551587105	0.9810925126075745	PNEUMONIA	PNEUMONIA	NEUMONIA
IM-0021.jpeg	0.005382522940635681	0.9946175217628479	PNEUMONIA	PNEUMONIA	NEUMONIA
IM-0022.jpeg	0.0379716195166111	0.9620283246040344	PNEUMONIA	PNEUMONIA	NEUMONIA
IM-0023.jpeg	0.01255388930439949	0.9874460697174072	PNEUMONIA	PNEUMONIA	NEUMONIA
IM-0024.jpeg	0.0022092978470027447	0.9977906942367554	PNEUMONIA	PNEUMONIA	NEUMONIA

ii. Matriz de Confusión de resultados Modelo

VP	FP	12	3	Imágenes con neumonía correctamente clasificadas	Imágenes "Normales" clasificadas como "Neumonía"
FN	VN	0	9	Imágenes con neumonía clasificadas como "Normales"	Imágenes "Normales" correctamente clasificadas

iii. Matriz de Confusión Especialista

VP	FP	12	8	Imágenes con neumonía correctamente clasificadas	Imágenes "Normales" clasificadas como "Neumonía"
FN	VN	0	4	Imágenes con neumonía clasificadas como "Normales"	Imágenes "Normales" correctamente clasificadas



III. Procedimiento para desarrollo de Experimentos de comparación de métricas modelo vs especialista

i. Pasos para seguir por el Especialista Médico

- Se adjuntan 24 imágenes de rayos X de pacientes con sospecha de diagnóstico de Neumonía.
- Descargar imágenes y guardarla en una Carpeta
- Abrir Archivo Excel Adjunto “Evaluación Especialista Médico “
- Guardar en Carpeta
- El especialista pondrá en cronómetro (celular, reloj; etc.) en 0 :00 y lo apagará una vez termine la definición del diagnóstico.
- Entregable: Excel con la columna Criterio Especialista completada con la opción Normal o Neumonía
- Debe categorizarse todas las imágenes aun cuando no se tenga claridad de una u otra opción, se elegirá la más probable
- Mencionar las imágenes más Difícil de Diagnosticar.
- Registro de Tiempo total del Diagnóstico de las 24 imágenes



ii. Formulario para completar por el especialista médico.

File name	Criterio Especialista	Imagen es difícil de diagnosticar ?
IM-0001.jpeg	NORMAL	NO
IM-0002.jpeg		
IM-0003.jpeg		
IM-0004.jpeg		
IM-0005.jpeg		
IM-0006.jpeg		
IM-0007.jpeg		
IM-0008.jpeg		
IM-0009.jpeg		
IM-0010.jpeg		
IM-0011.jpeg		
IM-0012.jpeg		
IM-0013.jpeg		
IM-0014.jpeg		
IM-0015.jpeg		
IM-0016.jpeg		
IM-0017.jpeg		
IM-0018.jpeg		
IM-0019.jpeg		
IM-0020.jpeg		
IM-0021.jpeg		
IM-0022.jpeg		
IM-0023.jpeg		
IM-0024.jpeg		